



学校代码: 10272

学 号: 2023213131

上海财经大学

SHANGHAI UNIVERSITY OF FINANCE AND ECONOMICS

硕 士 学 位 论 文

MASTER DISSERTATION

(专 业 硕 士)

论文题目: 物理信息神经网络在期权定价中的应用

培养院系: 数学学院

论文类别: 应用统计硕士专业学位论文

论文作者: 陈欣浩

指导教师: 张冉副教授

完成日期: 2025 年 6 月

学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品成果。对本人的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

论文作者签名：

日期： 年 月 日

学位论文版权使用授权书

(硕士学位论文用)

本人完全了解上海财经大学关于收集、保存、使用学位论文的规定，即：按照有关要求提交学位论文的印刷本和电子版本。上海财经大学有权保留并向国家有关部门或机构送交本论文的复印件和扫描件，允许论文被查阅和借阅。本人授权上海财经大学可以将学位论文的全部或部分内容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

论文作者签名：

导师签名：

日期： 年 月 日

日期： 年 月 日

摘 要

本论文提出了一种基于物理信息神经网络 (PINNs) 的方法, 用于求解期权定价方程的正问题和反问题。首先, 本文系统回顾了 Black-Scholes (BS) 方程、常弹性方差 (CEV) 方程和 Heston 随机波动率方程的基本理论及其在金融工程中的应用, 分析了传统数值方法 (如有限差分法和蒙特卡洛模拟法) 在求解这类偏微分方程时的局限性, 包括高维问题计算成本剧增、非线性方程求解稳定性差以及复杂边界条件适应性不足等问题。

为克服这些挑战, 本文构建了面向金融衍生品定价的 PINNs 框架体系。针对 BS 方程, 设计了包含时间、标的资产价格和波动率变量的多输入神经网络架构, 通过嵌入风险中性测度约束, 实现了欧式期权价格的高效求解, 并可同步反演隐含波动率曲面和市场风险偏好参数。在 CEV 模型求解中, 不仅构建了处理非线性波动率项的自适应激活函数网络结构, 成功求解了 CEV 方程的正问题, 还将 PINNs 应用于该模型的反问题, 从市场期权数据中精确识别出标的资产价格弹性系数和波动率基准参数。针对 Heston 模型这一二维非线性 PDE 问题, 本文提出双子网络耦合架构: 一个子网络逼近价格-波动率联合域内的期权价值函数, 另一个子网络建模随机波动率的动态演化过程, 通过共享参数层实现 Heston 特征函数的自动学习, 成功实现了带随机波动率和均值回归特性的期权定价正问题求解。

本研究证实了 PINNs 在金融工程领域的突破性潜力: 通过将金融物理定律深度嵌入机器学习框架, 不仅建立了统一求解确定性和随机波动率模型的深度学习范式, 更为高频交易环境下实时参数校准、隐含波动率曲面动态重构等实际问题提供了全新解决方案。研究结果为扩展 PINNs 在信用衍生品定价、多资产组合优化等复杂金融场景的应用提供了方法论基础。

关键词: 期权定价方程; PINNs; CEV 定价方程; 反问题

Abstract

This thesis proposes a Physics-Informed Neural Networks (PINNs)-based framework for solving both forward and inverse problems in option pricing equations.

First, the study systematically reviews the theoretical foundations of the Black-Scholes (BS) equation, Constant Elasticity of Variance (CEV) equation, and Heston stochastic volatility equation, along with their applications in financial engineering. It highlights the limitations of traditional numerical methods—such as finite difference methods and Monte Carlo simulations—in addressing these partial differential equations (PDEs), including exponential computational cost growth in high-dimensional problems, instability in nonlinear systems, and poor adaptability to complex boundary conditions.

To overcome these challenges, this work establishes a PINNs framework tailored for financial derivative pricing. For the BS equation, a multi-input neural network architecture incorporating time, underlying asset prices, and volatility parameters is designed. By embedding risk-neutral measure constraints into the loss function, the model efficiently computes European option prices while simultaneously inferring implied volatility surfaces and market risk preference parameters. In solving the CEV model, an adaptive activation function network structure is developed to handle the nonlinear volatility term, successfully addressing the forward problem. Furthermore, PINNs are applied to the inverse problem of the CEV model, enabling precise identification of key parameters—including the asset price elasticity coefficient and baseline volatility—from market option data. For the Heston stochastic volatility model—a two-dimensional nonlinear PDE problem—a dual-subnetwork coupled architecture is proposed: one subnetwork

approximates the option value function in the price-volatility joint domain, while another models the stochastic volatility dynamics. Through shared parameter layers, the architecture achieves automatic learning of the Heston characteristic function, effectively solving the forward pricing problem under stochastic volatility and mean-reverting behavior.

The research demonstrates the transformative potential of PINNs in financial engineering. By deeply integrating financial physical laws into machine learning frameworks, it establishes a unified deep learning paradigm for solving both deterministic and stochastic volatility models. This approach provides novel solutions for real-world challenges such as real-time parameter calibration in high-frequency trading environments and dynamic reconstruction of implied volatility surfaces. The findings offer a methodological foundation for extending PINNs to complex financial applications, including credit derivative pricing and multi-asset portfolio optimization.

Keywords: Option Pricing Equation; Physics-Informed Neural Networks; CEV Pricing Equation; Inverse Problems

目 录

摘要	I
Abstract	II
第一章 引言	1
1.1 选题背景与意义	1
1.2 研究的主要创新之处	4
第二章 理论基础	6
2.1 期权定价	6
2.1.1 标的资产分布	6
2.1.2 常用期权定价模型	10
2.2 物理信息神经网络 (PINNs)	15
2.2.1 全连接神经网络 (FCNN)	15
2.2.2 物理信息神经网络 (PINNs)	20
2.2.3 期权定价方程正问题求解	21
2.2.4 期权定价方程反问题求解	22
第三章 数值模拟及实例结果分析	29
3.1 PINNs 求解期权定价方程正问题	29
3.1.1 BS 期权定价方程的求解	29
3.1.2 CEV 定价模型的求解	35
3.1.3 Heston 定价模型的求解	37
3.2 PINNs 反推期权定价方程反问题参数	42
3.2.1 GARCH 模型波动率预估	43
3.2.2 BS 方程反问题参数反推	44
3.2.3 CEV 方程反问题实例参数反推	47

第四章 结论	49
4.1 研究成果	49
4.2 PINNs 算法优势	50
4.3 局限性与未来研究方向	51
4.4 研究意义	52
参考文献	55
第五章 致谢	58

第一章 引言

第一节 选题背景与意义

偏微分方程（Partial Differential Equations, PDEs）是描述自然界和工程领域中许多复杂现象的核心数学工具, 广泛应用于物理学、工程学、生物学、金融学等领域。例如, 热传导方程、波动方程和流体动力学中的 Navier-Stokes 方程均属于偏微分方程的经典范畴。偏微分方程通过描述未知函数的偏导数之间的关系, 刻画了时间与空间的演化规律, 是解析和数值研究的重要对象, 也是构建现代科学与工程理论体系的基石。

偏微分方程的求解目前有两种通用的方法, 解析解法和数值解法。解析解法通过数学推导获得问题的精确解, 但这通常仅适用于少数特定类型的偏微分方程, 如线性或具有特定对称性的方程。典型的解析方法包括变量分离法、积分变换法（如傅里叶变换和拉普拉斯变换）、特征线法以及幂级数展开等。这些方法直观且结果精确, 但其适用范围受限于问题的复杂性和终止条件或边界条件的特殊性。而由于实际问题中偏微分方程的复杂性和非线性特性, 许多情况下难以获得解析解, 因此需要通过数值方法来有效的逼近潜在的精确解。

数值解法通过离散化偏微分方程, 将其转化为代数方程求解, 从而得到近似解。主要的数值方法^[1] 包括有限差分法、有限元法和谱方法等。有限差分法基于网格点的差分逼近, 具有简单易实现的优点, 但在处理复杂几何和边界条件时表现有限。有限元法通过分片多项式逼近解决复杂几何问题, 可以方便地扩展到三维甚至更高维问题, 适合复杂的工程计算, 在工程领域得到广泛应用, 但其计算成本高且网格划分困难, 实现复杂度较高。谱方法则利用全局基函数展开, 在高精度问题中表现优异, 但对网格规则性要求较高。

尽管这些方法应用广泛, 但在用于高维问题和反问题时, 这些方法被证明具有挑战性。例如, 可以证明对于抛物型线性偏微分方程和张量积网格, 有限元离散化误差的时间复杂度为 $\mathcal{O}(N^{-\frac{2}{d}})$, 其中 N 为网格点的数量, d 为空间维度。可

以发现, 对于固定的 N , 离散化误差的时间复杂度随空间维数 d 指数级增长。

在现代金融市场中, 价格波动、风险管理和资产定价等问题已经成为研究的核心议题。为了深入理解和预测这些复杂的市场行为, 数学方法尤其是偏微分方程 (PDE) 在金融工程学中的应用变得至关重要。偏微分方程通过建立动态模型来描述金融工具价格与时间、空间变量之间的关系, 尤其是在期权定价、风险中立测度、最优投资决策等领域展现了其强大的分析能力。经典的金融数学模型, 如布莱克-斯科尔斯期权定价模型, 正是通过偏微分方程的框架来描述资产价格变化的过程。

金融产品的创新与发展始终与金融数学的理论研究密切相关, 其中衍生品作为现代金融市场的重要组成部分, 对定价模型的研究尤为关键。早期的研究集中于股票、债券等基础金融产品的估值 (Merton, 1973), 随着市场的复杂化, 期权等衍生品的定价问题逐渐成为研究热点。期权 (Option) 是一种金融衍生品, 赋予持有人在特定时间内按约定价格买入或卖出某项资产, 如股票、商品或其他金融工具的权利。期权交易是基于资产未来价格的波动性, 期权本身的价值由标的资产的价格、波动性、到期时间等因素决定, 其定价方法是金融工程领域的重要研究方向。

期权定价的研究^[2] 最早可以追溯到 Bachelier (1900), 其研究基于布朗运动理论描述资产价格的随机特性。然而, 现代意义上的期权定价理论则以 Black 和 Scholes (1973) 及 Merton (1973) 的研究为里程碑。他们提出了著名的布莱克-舒尔斯 (Black-Scholes, BS) 模型, 通过假设市场无套利、资产价格服从几何布朗运动、波动率恒定等, 导出了一个偏微分方程用于计算期权的理论价格。

BS 模型的提出不仅解决了期权定价的基础问题, 还为金融市场的风险管理提供了理论支持。然而, 模型的简化假设, 如波动率恒定、市场完全性, 在真实市场中难以完全满足, 这激发了后续大量的扩展研究。例如, Heston (1993) 引入随机波动率模型, Duffie 等 (2000) 研究了跳跃扩散过程对期权价格的影响, 这些工作极大地丰富了期权定价理论。

期权定价模型的实际应用不仅限于理论价格的计算, 更在金融产品设计、风

险管理、对冲策略制定等方面发挥了重要作用。例如, 隐含波动率的计算已成为市场情绪的重要指标, 而期权定价方程作为工具被广泛用于隐含波动率曲面的生成。然而, 随着市场条件的复杂化, 真实数据中的不对称波动率、市场摩擦、交易成本等问题暴露了期权定价模型的局限性。为此, 许多研究者提出了改进模型^[3,4], 如局部波动率模型和动态波动率模型, 试图更准确地反映市场特性。

由于期权定价方程的解析解仅在特定条件下存在, 对于更复杂的市场结构或衍生品类型 (如美式期权、障碍期权), 需要借助数值方法^[5] 求解期权定价方程。有限差分法 (FDM)^{[6][7]}、有限元法 (FEM)^[8]、蒙特卡洛模拟 (Monte Carlo Simulation)^{[9][10][11]} 和二叉树 (Binary Tree)^{[12][13][10]} 是主要的数值方法。其中, FDM 因其效率和易实现性被广泛应用, 但在高维问题中受到维数灾难的限制。例如, 使用有限差分法或有限元法解决高维 PDE 时, 计算所需的存储和运算量呈指数级增长, 使得解决高维金融问题, 如多资产期权、复杂衍生品定价等变得非常困难和低效。对于一些复杂的期权定价问题, 可能需要极细的网格或大量的模拟路径才能得到满意的结果, 这更增加了计算成本。因此, 相较于传统方法而言, 我们需要更加高效的数值方法来实现偏微分方程解的快速计算。

机器学习和深度学习是近年来人工智能领域最为活跃和重要的研究方向, 被广泛应用于图像识别、语音处理、自然语言处理、推荐系统等领域。由于深度神经网络具有通用逼近性质, 即每一个连续的、甚至可测的函数都可以由深度神经网络来逼近, 因此使用深度神经网络作为偏微分方程的逼近是直观且易于实现的^{[14][15]}。例如有研究将深度学习与传统数值方法, 如有限元法、有限差分法^[16] 等相结合, 形成混合方法, 以提高求解偏微分方程的精度和效率。例如 Weinan E 在^[17] 介绍了利用非线性蒙特卡罗方法和深度学习技术的方法求解高维偏微分方程算法的最新进展。卷积神经网络 (CNN)^[18] 也已经被用于通过学习特征表示来求解一些标准的 PDE 问题, 尤其是在计算机视觉相关的 PDE 问题 (如图像分割) 中, CNN 提供了一种高效的替代方案。

PINNs 的理论根基源于对偏微分方程 (PDE) 求解的创新性尝试。Raissi、Perdikaris 和 Karniadakis 在 2019 年发表的论文^[19] 中, 系统阐述了 PINNs 的核

心架构。近年来,物理信息神经网络(PINNs)作为深度学习与科学计算交叉融合的前沿技术,利用PINNs求解偏微分方程(PDEs)^{[20][21][22][23]}是一个非常活跃的研究方向。PINNs通过将PDE的物理约束(即方程的残差)嵌入到神经网络的损失函数中,实现了无网格的求解方法,且不依赖传统的数值离散化方法。这种方法在求解波动方程、热方程、欧拉方程、纳维-斯托克斯方程(Navier-Stokes equations)和多物理场耦合问题时已经被证明是高效且准确的。而在金融领域,Heston模型^[24]是一种著名的随机波动率模型,描述了期权定价中的波动率随机过程。Heston方程是一个具有随机波动率的PDE,传统方法求解时可能会遇到高维难题。PINNs可以在不依赖网格的情况下,通过最小化PDE残差来有效求解此类问题,尤其在高等期权定价问题中展现了独特的优势。

本文的目标是展示物理信息神经网络(PINNs)在金融领域期权定价中的应用,例如求解布莱克-斯科尔斯(Black-Scholes)模型和CEV定价模型。同时也展示了物理信息神经网络(PINNs)在求解反问题时的有效性,期权定价的反问题指的是根据市场数据推导模型未知参数(如波动率、利率等)。PINNs能够有效地结合观测数据和物理约束来推导反问题中的未知参数,特别是在金融市场存在噪声数据时,PINNs展现出强大的鲁棒性。

第二节 研究的主要创新之处

(1) 金融实例的应用:将期权定价方程通过PINNs的求解方法应用到了真实的金融市场中,通过将市场的真实交易数据作为边界条件或优化约束,PINNs能够实现从理论模型到实际应用的无缝衔接。这种数据驱动和理论驱动的结合使得模型既具备对真实市场的适应能力,又保持了金融理论的解释性。

(2) 期权定价方程的参数反问题:利用PINNs求解期权定价方程的参数反问题,能够在无需明确隐含波动率或其他复杂市场参数的情况下,通过市场观察到的期权价格反推出关键定价参数(如隐含波动率、风险中性概率等),从而在理论模型与真实市场数据之间建立直接联系,为动态校准模型参数、改进期权定价和风险管理提供了一种高效且泛化性强的新方法。

(3) 非线性期权定价方程正问题的求解：将 PINNs 应用于非线性模型的期权定价正问题求解，通过结合偏微分方程的物理约束与数据驱动的深度学习方法，显著提高了非线性波动率环境下的解算效率与精度，为复杂金融衍生品的定价提供了新思路。

这些创新不仅体现了深度学习在金融问题中的应用扩展，也提供了一种新的思路来处理传统上难以解决的问题。通过实证分析和详细的实验，本文验证了这些创新方法的有效性和实用性。

第二章 理论基础

第一节 期权定价

2.1.1 标的资产分布

期权是一种金融衍生工具, 允许其持有者在约定的时间或之前, 按照约定的价格买入或卖出某种标的资产 (如股票、商品、货币等)。但期权的持有者并不被强制执行该权利。因此, 期权是一种带有选择性的合约, 具有非对称的风险和收益特性。期权赋予买方权利, 但不强制执行; 而期权的卖方则承担履行合约的义务。期权市场中的参与者分为两类: 买方 (持有期权的人) 和卖方 (提供期权的人)。买方支付期权费 (premium) 购买权利, 而卖方则收到期权费, 即期权在 $t = 0$ 时的价格, 并承担履行合约的责任。当期权买方决定以合约规定的价格买入或卖出标的资产时, 即为“行权”。期权合约的有效期, 期权在到期日后失效。如果期权在到期日未行使, 则失去价值。

期权有多种类型, 主要根据不同的行权方式、标的资产和交易方式进行分类。以下是最常见的期权种类。

根据期权的类型分类可以分为看涨期权和看跌期权。看涨期权 (Call Option) 赋予持有者在特定日期或之前按约定的行权价格购买标的资产的权利。投资者购买看涨期权时, 预期标的资产的价格会上涨。看跌期权 (Put Option) 赋予持有者在特定日期或之前按约定的行权价格卖出标的资产的权利。投资者购买看跌期权时, 预期标的资产的价格会下跌。这两种期权的主要区别在于: 看涨期权适用于投资者看好市场, 期望价格上涨。看跌期权适用于投资者看空市场, 期望价格下跌。

期权的行权时间决定了买方可以在何时行使权利。按行权时间分, 期权主要欧式期权和美式期权两类。欧式期权 (European Option) 只能在到期日当天行权。即期权买方在到期日当天才能决定是否执行期权。而美式期权 (Ameri-

can Option) 可以在到期日之前的任何一个交易日行权, 包括到期日当天。它比欧式期权更具灵活性, 因为买方有更长的时间窗口来行使期权。百慕大式期权 (Bermudan Option), 这种期权介于欧式期权和美式期权之间, 买方可以在特定的日期 (而不是所有日期) 行权。通常, 这种期权的行权日期是事先约定好的, 往往用于某些特定的衍生品和结构化产品。

亚式期权 (Asian Option), 又称为平均期权, 是一种基于标的资产价格的平均值来计算收益的期权。这种期权的行权价格或者收益是基于标的资产在整个期权生命周期内价格的算术平均值或几何平均值, 而不是期权到期时的单一价格。

而期权价格 (Option Price) 主要由内在价值和时间价值两部分组成, 其中内在价值 (Intrinsic Value) 是指期权当前的实际价值。对于看涨期权来说, 它的内在价值为 $\max(S - K, 0)$, 看跌期权为 $\max(K - S, 0)$, 其中, S 是标的资产价格, K 是行权价格。时间价值 (Time Value) 是指期权价格中超出内在价值的部分, 反映了期权未到期前因价格波动可能获得的额外价值。此外, 期权的非对称性使其持有人享有权利, 但无行权义务, 这与期货等其他衍生品形成鲜明对比。

期权在风险对冲中扮演关键角色。例如, 企业可利用看跌期权锁定未来资产价格, 降低价格下跌的风险。投资者通过期权交易利用杠杆效应以较低成本博取标的资产价格波动带来的高收益。期权可用于设计保护性投资组合, 如购买保护性看跌期权以限制潜在损失。

期权作为金融衍生品, 由上文所述, 其价值由标的资产的价格、波动性、到期时间等因素决定, 所以它是标的资产价格 S 和时间 t 的函数, 即 $u = u(S, t)$, 假设我们的标的资产服从以下随机过程 (2-1):

$$dS_t = \mu(t, S_t)S_t dt + \sigma(t, S_t)S_t dB_t, \quad (2-1)$$

其中:

$\mu(t, S_t)$ 是资产的漂移率, 反映价格的平均增长趋势;

$\sigma(t, S_t)$ 是资产的波动率, 衡量价格的随机性强度;

dB_t 是布朗运动的增量, 描述资产价格的随机波动。

具体来说, 布朗运动 B_t 是具有以下性质的随机过程:

- (1) 初值为 0: $B_0 = 0$;
- (2) 独立增量: 对于任意不重叠的时间区间, 增量 $B_{t+s} - B_t$ 和 $B_t - B_{t-u}$ 是相互独立的;
- (3) 增量服从正态分布: $B_{t+s} - B_t \sim N(0, s)$;
- (4) 轨迹连续但不可微: 布朗运动路径在时间上连续, 但在几乎所有点上不可微。

这个模型 (2-1) 体现了资产价格的两个重要特性, 第一个是随机性, 价格变化中包含不可预测的成分。第二个是对数收益正态分布, 资产价格在长期中保持非负性。

接着我们需要引入伊藤公式定理 (2.1), 它可以用来处理基于基础资产波动假设来计算衍生证券波动的情况, 因为期权合约和股票 S 的关系也是由一个确定性关系 $u(S_t, t)$ 获得。

定理 2.1 (Itô 公式): 设 $u_t = u(S_t, t)$, $u \in \mathbb{C}^{2,1}(\mathbb{R} \times [0, \infty])$ 是二元可微函数。若随机过程 S_t 适合随机微分方程

$$dS_t = \mu(S_t, t)S_t dt + \sigma(S_t, t)S_t dB_t,$$

则

$$\begin{aligned} du_t &= \left(\frac{\partial u}{\partial t} + \frac{1}{2} \sigma^2(S_t, t) \frac{\partial^2 u}{\partial S^2} \right) dt + \frac{\partial u}{\partial S} dS_t \\ &= \left(\frac{\partial u}{\partial t} + \mu(S_t, t) \frac{\partial u}{\partial S} + \frac{1}{2} \sigma^2(S_t, t) \frac{\partial^2 u}{\partial S^2} \right) dt + \sigma(S_t, t) \frac{\partial u}{\partial S} dB_t. \end{aligned}$$

对于期权定价模型, 我们作如下假设:

- (1) 无风险利率常数 r : 假设市场上存在一个无风险的利率 r , 并且该利率是固定的。无风险利率通常指的是国债等安全资产的收益率;
- (2) 波动率 σ : 是市场对标的资产未来价格波动性的一种预期, 反映了期权交易者对标的资产未来走势不确定性的估计。
- (3) 无股息支付: 该模型假设股票不支付股息。如果股票支付股息, 这会影

响到期权的定价, 因为股息支付减少了股票的预期回报;

(4) 无套利机会: 假设市场是完全竞争的, 没有套利机会。套利指的是在没有风险的情况下获得无风险利润。通过无套利条件, 可以得到期权定价的核心方程;

(5) 市场是完美的: 假设市场是完美流动的, 没有交易成本、税收或其他摩擦, 所有信息都是完全且立即可得的;

期权定价模型的核心是基于复制组合 (Replication Portfolio) 和无套利定价原理来推导期权的价格。复制组合是指在没有套利的市场中, 期权的价格必须等于一个无风险资产组合的价格, 该组合包括股票和无风险资产 (如国债)。通过购买一定比例的股票并借入一定数量的无风险资产 (例如债券), 我们可以复制期权的收益结构。无套利条件是指假设我们可以构造一个“复制组合”, 它的风险敞口和期权相同。由于市场没有套利机会, 我们可以根据复制组合的无风险回报率来推导期权的价格。在推导的过程中, 期权定价模型采用了一个关键的工具——风险中性定价 (Risk-Neutral Pricing)。通过应用伊藤定理 (2.1) 对股票价格的随机过程2-1进行展开, 结合风险中性定价原理, 可以得出期权价格 $u(S, t)$ 的偏微分方程, 表示为:

$$\frac{\partial u}{\partial t} dt + r(S, t) S \frac{\partial u}{\partial S} + \frac{1}{2} \sigma^2(S, t) S^2 \frac{\partial^2 u}{\partial S^2} - ru = 0, \quad (2-2)$$

由公式 (2-2) 可以得到一般的期权定价模型 (2-3) 如下所示:

$$\begin{cases} \frac{\partial u}{\partial t} = L_S(u; \lambda), (S, t) \in [0, +\infty) \times [0, T] \\ u(S, T) = u_T(S) \\ u(S, t) = u(t), S \in [0, +\infty) \end{cases} \quad (2-3)$$

其中 λ 为参数集合, T 代表的是期权到期时间。PDE 的初值条件对于期权定价模型来说为终止条件。

2.1.2 常用期权定价模型

2.1.2.1 BS 期权定价方程

Black-Scholes 期权定价模型是由 Fischer Black、Myron Scholes 和 Robert Merton 于 1973 年提出, 对于一个欧式看涨期权来说, BS 期权定价方程可以写为:

$$\frac{\partial u}{\partial t} + rS \frac{\partial u}{\partial S} + \frac{1}{2} \sigma^2 S^2 \frac{\partial^2 u}{\partial S^2} = ru, \quad (2-4)$$

终止条件为 $u(S_T, T) = \max(S_T - K, 0)$ 。

对于这个线性的 BS 方程是存在解析解的, 欧式看涨期权的价格为

$$u(S, t) = SN(d_1) - Ke^{-r(T-t)}N(d_2), \quad (2-5)$$

其中 $N(x)$ 是标准正态分布, $d_1 = \frac{\ln(\frac{S}{K}) + (r + \frac{\sigma^2}{2})(T-t)}{\sigma\sqrt{T-t}}$, $d_2 = d_1 - \sigma\sqrt{T-t}$ 。

d_1 和 d_2 这两个参数代表了期权到期时股票价格和执行价格之间的关系, 考虑了波动性和无风险利率的影响。 d_1 反映了期权的“delta”, 即期权价格相对于股票价格的敏感度。 d_2 反映了实际执行期权 (即 $S > K$) 的风险中性概率。 $N(d_1)$ 和 $N(d_2)$ 表示在标准正态分布下, 股票价格到期时高于或低于行使价格的概率。看涨期权的现值部分是当前股票价格的折现部分 $SN(d_1)$ 。BS 方程的解析解可以帮助我们在后续验证算法的误差。

2.1.2.2 CEV 定价方程

在实际的金融市场中, 波动率通常不是常数, 而是随着市场条件、时间和资产价格的变化而变化。尤其是在期权定价中, 市场中经常出现所谓的波动率微笑 (volatility smile) 和波动率偏斜 (volatility skew) 现象。这些现象说明隐含波动率随执行价格和到期时间的变化而变化。经典的 Black-Scholes 模型假设波动率是常数, 这限制了其在实际市场中的表现。

CEV (Constant Elasticity of Variance) 模型的提出, 是为了改进 Black-Scholes 模型中的这个假设。CEV 模型允许波动率根据资产价格的变化而变化, 特别是考虑到波动率对资产价格大小的非线性依赖性。通过引入一个弹性指数

β , CEV 模型可以更好地拟合市场中的波动率微笑和偏斜现象。

在 CEV 模型中, 资产价格 S_t 的随机微分方程为 $dS_t = \mu S_t dt + \sigma S_t^\beta dB_t$, 漂移项 $\mu S_t dt$ 与资产价格 S_t 成正比, 表示资产的平均变化, 通常与预期收益相关。扩散项 $\sigma S_t^\beta dB_t$ 表示波动率依赖于资产价格, 波动率的大小随着 S_t^β 的变化而变化。其中 β 控制了波动率对价格的敏感度。

与传统的 Black-Scholes 模型假设的常数波动率不同, CEV 模型假设波动率与资产价格成非线性关系, 波动率的大小随着资产价格的变化而变化。这个关系通过弹性指数 β 来控制, 当 $\beta = 1$ 时, CEV 模型退化为 Black-Scholes 模型, 波动率为常数, 这种模型假设市场中没有波动率微笑和偏斜, 适用于那些波动率相对平稳的市场。当 $\beta < 1$ 时, 波动率随着资产价格的下降而增加, 这是典型的波动率微笑现象。在金融市场中, 较低价格的资产或期权通常会有较高的波动率, 尤其是对于深度虚值期权或某些高风险资产, 这种现象尤为明显。此时的波动率偏向于隐含波动率的升高, 即价格越低, 波动率越大。低价资产的波动率往往较大, 因为低价资产的市场情绪和市场反应往往比高价资产更剧烈。因此, 波动率对于低价资产来说通常更为敏感, 可能呈现上升的趋势。当 $\beta > 1$ 时, 波动率随着资产价格的上升而增加。这种情况较少见, 但在某些特定市场中可能出现, 例如对于某些高价资产或者在极端市场条件下, 波动率可能随着价格的上涨而增加。高价资产的波动率可能随着价格的增加而加大。这通常出现在大宗商品或一些金融资产中, 其中资产价格的上涨可能会带来更多的市场不确定性或投机行为, 导致波动率上升。 β 的变化直接影响期权的定价, 尤其是在不同执行价格和到期时间的期权中。波动率的变化对期权价格的影响往往比其他因素更为敏感, 因此通过调节 β , CEV 模型能够更好地拟合不同市场条件下的期权价格。

由于市场中的隐含波动率往往随行权价格和到期时间的变化而变化, CEV 模型通过波动率与资产价格的非线性关系由 S_t^β 描述能够较好地拟合这些现象。

相比于 Black-Scholes 模型, CEV 模型能够灵活地根据市场数据调整波动率结构, 特别是在面对波动率微笑和偏斜的市场中, CEV 模型具有显著的优势, CEV 模型能够通过调整弹性指数 β 来捕捉波动率微笑现象, 尤其适合低价股票

和期权的定价, CEV 模型能够根据资产价格的变化, 调整波动率的大小, 从而更好地模拟风险和回报的不对称性。

下面, 我们给出 CEV 模型下期权价格的偏微分方程。设 $u(S, t)$ 为期权的价格, 标的资产的价格为 S , 无风险利率为 r , 弹性指数为 β , 期权的到期时间为 T , 则期权价格满足如下偏微分方程:

$$\frac{\partial u}{\partial t} + rS \frac{\partial u}{\partial S} + \frac{1}{2} \sigma^2 S^{2\beta} \frac{\partial^2 u}{\partial S^2} = ru, \quad (2-6)$$

这与 Black-Scholes 模型的 PDE 公式 (2-4) 形式类似, 唯一的不同是波动率项变为 $\sigma^2 S^{2\beta}$, 因此该方程能够灵活地根据资产价格的不同, 调整波动率的大小。

接着我们给出欧式看跌期权 CEV 模型的解析解用于后续的误差对比。欧式看跌期权 $p(S_t, t, K, r, \sigma)$ 的解为:

$$p(S_t, t, K, r, \sigma) = \begin{cases} Ke^{-r(T-t)} Q\left(2x; \frac{2}{2-\beta}, 2y\right) - S_t \left[1 - Q\left(2y; 2 + \frac{2}{2-\beta}, 2x\right)\right], & \text{若 } \beta < 2, \\ Ke^{-r(T-t)} Q\left(2y; 2 + \frac{2}{\beta-2}, 2x\right) - S_t \left[1 - Q\left(2x; \frac{2}{\beta-2}, 2y\right)\right], & \text{若 } \beta > 2, \end{cases} \quad (2-7)$$

其中, $Q(w; v, \lambda)$ 是非中心卡方分布的补充分布函数, v 是自由度, λ 是非中心参数, 并且

$$x = S_t^{2-\beta} e^{r(2-\beta)(T-t)} d, \quad (2-8)$$

$$d = \frac{2r}{\delta^2(2-\beta) [e^{r(2-\beta)(T-t)} - 1]}, \quad (2-9)$$

$$\delta^2 = \sigma_0^2 S_0^{2-\beta}. \quad (2-10)$$

CEV 模型主要有以下两个优点, 第一个是灵活性较强, CEV 模型能够根据市场的实际波动率结构调整模型的参数 β 。特别是在面对波动率微笑和偏斜的市场现象时, CEV 模型展现了强大的灵活性。另一个优点则是适应性更好, 与 Black-Scholes 模型相比, CEV 模型能够更好地拟合那些波动率随资产价格变化的情况, 尤其在波动率微笑和偏斜现象较为明显的市场中表现更好。同样, CEV 模型也有一些缺点, 例如模型参数估计困难, CEV 模型需要估计多个参数, 如 μ, σ 和 β , 这些参数的估计往往依赖历史数据, 可能面临一定的拟合问题。但对于反问题来说, 本文后续所提到的 PINNs 对于反问题的求解是较为方便的。另

一个缺点则是非线性复杂性, CEV 模型的非线性性质使得其解析解的推导比较复杂, 通常需要通过数值方法来进行求解, 这可能导致计算成本较高。第三点则是对波动率微笑的建模有局限, 尽管 CEV 模型能较好地拟合波动率微笑现象, 但它仍然假设波动率的变化具有某种特定的功能形式, 可能无法捕捉市场的所有复杂波动率特征。

总的来说, CEV 模型通过引入与资产价格相关的波动率, 提供了一种更为灵活的期权定价模型。通过调整波动率的弹性指数 CEV 模型能够更好地拟合市场中常见的波动率微笑和偏斜现象, 特别是在股票市场和商品市场等实际应用中。在期权定价方面, CEV 模型的引入为金融工程提供了更多的工具和选择, 使得期权定价和风险管理更为精准。然而, 它也面临着参数估计和数值解法的挑战, 特别是在复杂的金融市场环境中。

2.1.2.3 Heston 定价方程

Heston 模型是一种在金融衍生品定价中广泛应用的随机波动率 (Stochastic Volatility) 模型, 由经济学家 Steven Heston 于 1993 年提出。它通过引入波动率的随机过程, 克服了 Black-Scholes 模型中波动率恒定的假设, 能够更好地解释市场中的波动率微笑 (Volatility Smile) 和波动率期限结构现象。Black-Scholes 模型假设波动率是常数, 但实证研究表明, 波动率在现实中是随时间变化的, 并且不同行权价和期限的期权价格无法用单一波动率解释, 导致波动率微笑的出现。Heston 模型通过允许波动率本身成为随机过程, 并且波动率与资产价格相关, 解决了 Black-Scholes 的局限性, 同时通过特征函数方法保持了解析解的存在性。它将波动率视为一个独立的 CIR 过程, 允许波动率自身具有随机性, 而无需依赖资产价格的路径。波动率会围绕长期均值 θ 波动, 符合现实市场中波动率的均值回归现象, 如危机后波动率逐渐回归正常水平。而参数 θ 可直接解释市场长期波动率的预期水平。

Heston 模型由两个耦合的随机微分方程 (SDEs) 组成:

资产价格的 SDE:

$$dS_t = \mu S_t dt + \sqrt{v_t} S_t dW_t^1, \quad (2-11)$$

其中 S_t 为资产价格, μ 为资产价格的漂移率 (通常设为无风险利率 r), v_t 为波动率过程 (方差), W_t^1 为标准布朗运动。

波动率的 SDE (CIR 过程):

$$dv_t = \kappa(\theta - v_t)dt + \xi\sqrt{v_t}dW_t^2, \quad (2-12)$$

其中 κ 为波动率的均值回复速度, 控制波动率向长期均值 θ 的回归速度。 θ 为波动率的长期均值。 ξ 为波动率的波动率 (volatility of volatility)。 W_t^2 为另一个标准布朗运动, 与 W_t^1 的协方差为 ρdt , 即:

$$dW_t^1 dW_t^2 = \rho dt.$$

ρ 是两者的相关系数, 通常为负值, 表示资产价格下跌时波动率上升, 能解释波动率微笑的倾斜。

为了确保波动率 v_t 非负, Heston 采用 CIR 过程, 其参数需满足 Feller 条件:

$$2\kappa\theta \geq \xi^2.$$

否则波动率可能变为负值。

Heston 的随机微分方程可以转换成偏微分方程 (PDE) 形式, 用于数值求解和期权定价:

$$\frac{\partial u}{\partial t} + \frac{1}{2}vS^2\frac{\partial^2 u}{\partial S^2} + \rho\sigma vS\frac{\partial^2 u}{\partial S\partial v} + \frac{1}{2}\sigma^2 v\frac{\partial^2 u}{\partial v^2} + rS\frac{\partial u}{\partial S} + \kappa(\theta - v)\frac{\partial u}{\partial v} - ru = 0, \quad (2-13)$$

其中 $u = u(S, v, t)$ 是期权价格, r 是无风险利率。

Heston 模型通过特征函数方法推导出欧式期权价格的解析解, 具体步骤如下:

Heston 证明了联合过程 (S_t, v_t) 的特征函数存在解析表达式:

$$\phi(u; t) = \mathbb{E} [e^{iu \ln S_t}],$$

其中 $\phi(u; t)$ 的具体形式涉及复数域上的积分, 可通过求解 PDE 获得。

利用特征函数和傅里叶逆变换, 将期权价格表示为复数积分:

$$u(S_0, K, T) = S_0 - \frac{K}{\pi} \int_0^\infty \operatorname{Re} \left[\frac{e^{-iu \ln K} \phi(u - i; T)}{u^2 + u} \right] du,$$

其中 K 是行权价, T 是到期时间。

在实际计算中, 使用数值积分方法, 如 Laplace 变换或数值积分法近似计算上述积分。

Heston 模型通过引入随机波动率和灵活的参数结构, 显著超越了 Black-Scholes 模型的局限性, 成为金融工程中解释波动率动态和定价复杂衍生品的核心工具。其解析解的存在性、对波动率微笑的解释能力以及可扩展性, 使其在学术研究和实际应用中占据重要地位。尽管存在参数校准复杂等挑战, 但其优点使其成为金融建模的基石之一。

第二节 物理信息神经网络 (PINNs)

2.2.1 全连接神经网络 (FCNN)

神经网络通常被视为一种非线性模型, 其基本构成单元是带有非线性激活函数的神经元。通过大量神经元之间的连接, 神经网络展现出高度的非线性特性。这些神经元之间的连接权重是需要学习的参数, 通常在机器学习框架中通过梯度下降法进行优化和更新。

全连接神经网络是指相邻两层之间的神经元是完全两两相连的。也就是说, 前一层的每个神经元都与后一层的每个神经元有连接。第一层有 m 个神经元, 第二层有 n 个神经元, 那么从第一层到第二层就有 $m \times n$ 个连接权重。

假设我们有如下记号:

令输入向量 $a^{(0)} = x$, 前馈神经网络通过不断迭代以下公式来逐层传播信息:

具体而言, 首先依据第 $l-1$ 层神经元的输出 $a^{(l-1)}$ 来计算第 l 层神经元的净输入 $z^{(l)}$, 随后通过一个激活函数得到第 l 层神经元的输出。由此, 我们可将每个神经元视为一个仿射变换与一个非线性变换的组合, 可以写为:

$$a^{(l)} = f_l(W^{(l)}a^{(l-1)} + b^{(l)}).$$

表 2-1 FCNN 记号

记号	含义
L	神经网络的层数
M_l	第 l 层神经元的个数
$\sigma_l(\cdot)$	第 l 层神经元的激活函数
$W^{(l)} \in \mathbb{R}^{M_l \times M_{l-1}}$	第 $l-1$ 层到第 l 层的权重矩阵
$b^{(l)} \in \mathbb{R}^{M_l}$	第 $l-1$ 层到第 l 层的偏置
$z^{(l)} \in \mathbb{R}^{M_l}$	第 l 层神经元的净输入
$a^{(l)} \in \mathbb{R}^{M_l}$	第 l 层神经元的输出

整个网络可被视作一个复合函数

$$\phi(x; W, b),$$

其中, W 和 b 分别表示网络中所有层的连接权重与偏置。

前馈神经网络具备强大的拟合能力, 其非线性拟合能力可由通用近似定理予以保证。常见的连续非线性函数都可以借助前馈神经网络来近似。

而常用的包括了 *sigmoid* 型函数、*ReLU* 型函数和 *Swish* 型函数等。*sigmoid* 型函数是一类 S 型曲线函数, 为两端饱和函数。常用的 *sigmoid* 型函数有 Logistic 函数和 Tanh 函数。其中, *sigmoid* 型函数是一类 S 型曲线函数, 为两端饱和函数。常用的 *sigmoid* 型函数有 *Logistic* 函数和 *Tanh* 函数。

Logistic 函数为

$$\sigma(x) = \frac{1}{1 + \exp(-x)}.$$

Tanh 函数为

$$\tanh(x) = \frac{\exp(x) - \exp(-x)}{\exp(x) + \exp(-x)} = 2\sigma(2x) - 1.$$

Tanh 函数的输出是零中心化 (zero-centered), 非零中心化的输出会使其后一层神经元的输入发生偏置偏移 (bias shift), 并进一步降低梯度下降的收敛速度。

而 ReLU (Rectified Linear Unit, 修正线性单元), 也叫 Rectifier 函数。ReLU

实际上是一个斜坡（ramp）函数。是目前深度神经网络中常用的激活函数。

$$\text{ReLU}(x) = \begin{cases} x & \text{if } x \geq 0 \\ 0 & \text{if } x < 0 \end{cases} = \max(0, x).$$

ReLU 函数计算高效, 具有很好的符合生物学特性的稀疏激活性（在生物神经网络中, 同时处于兴奋状态的神经元非常稀疏）, 但输出是非零中心化的。此外还比较容易出现死亡 ReLU 问题, 即在训练时, 如果参数在一次不恰当的更新后, 隐藏层中的某个神经元在所有的训练数据上都不能被激活, 那么这个神经元自身参数的梯度永远都会是 0, 在以后的训练过程中永远不能被激活。

而 *LeakyReLU* 的提出较好的解决了这个问题, 在输入 $x < 0$ 时, 保持一个很小的斜率 γ 。这样当神经元非激活时也能有一个非零的梯度可以更新参数, 以免不能被激活。

$$\text{LeakyReLU}(x) = \begin{cases} x & \text{if } x > 0 \\ \gamma x & \text{if } x \leq 0 \end{cases} = \max(0, x) + \gamma \min(0, x).$$

而 *Swish* 型函数是一种自门控 (self-gated) 激活函数。其中 β 是可学习的参数或一个固定的超参数。

$$\text{swish}(x) = x\sigma(\beta x).$$

对于样本 $(\mathbf{x}, \mathbf{y})$, 假设其损失函数为 $\mathcal{L}(\mathbf{y}, \hat{\mathbf{y}})$ 。给定训练集 $\mathcal{D} = \{(\mathbf{x}^{(n)}, \mathbf{y}^{(n)})\}_{n=1}^N$, 将每个样本 $\mathbf{x}^{(n)}$ 输入至神经网络, 可得到网络输出 $\hat{\mathbf{y}}^{(n)}$, 其在数据集 $\mathcal{D}$ 上的损失函数为:

$$\mathcal{R}(\mathbf{W}, \mathbf{b}) = \frac{1}{N} \sum_{n=1}^N \mathcal{L}(\mathbf{y}^{(n)}, \hat{\mathbf{y}}^{(n)}),$$

其中 $\mathbf{W}$ 和 $\mathbf{b}$ 分别表示网络中所有的权重矩阵和偏置向量。

有了学习准则和训练样本, 网络参数可通过梯度下降法进行学习。在梯度下降方法的每次迭代中, 第 l 层参数 $\mathbf{W}^{(l)}$ 和 $\mathbf{b}^{(l)}$ 的更新方式如下:

$$\mathbf{W}^{(l)} \leftarrow \mathbf{W}^{(l)} - \alpha \frac{\partial \mathcal{R}(\mathbf{W}, \mathbf{b})}{\partial \mathbf{W}^{(l)}} = \mathbf{W}^{(l)} - \alpha \left(\frac{1}{N} \sum_{n=1}^N \frac{\partial \mathcal{L}(\mathbf{y}^{(n)}, \hat{\mathbf{y}}^{(n)})}{\partial \mathbf{W}^{(l)}} \right),$$

$$\mathbf{b}^{(l)} \leftarrow \mathbf{b}^{(l)} - \alpha \frac{\partial \mathcal{R}(\mathbf{W}, \mathbf{b})}{\partial \mathbf{b}^{(l)}} = \mathbf{b}^{(l)} - \alpha \left(\frac{1}{N} \sum_{n=1}^N \frac{\partial \mathcal{L}(\mathbf{y}^{(n)}, \hat{\mathbf{y}}^{(n)})}{\partial \mathbf{b}^{(l)}} \right),$$

其中, α 为学习率。

梯度下降法需要计算损失函数对参数的偏导数, 若通过链式法则逐一对每个参数求偏导, 效率较低, 在神经网络的训练中通常使用反向传播算法来高效地计算梯度。

假设采用随机梯度下降法进行网络参数学习, 给定一个样本 $(\mathbf{x}, \mathbf{y})$, 将其输入到神经网络模型中, 得到网络输出为 $\hat{\mathbf{y}}$, 假设损失函数为 $\mathcal{L}(\mathbf{y}, \hat{\mathbf{y}})$, 要进行参数学习就需要计算损失函数关于各参数的导数。

不失一般性, 对第 l 层中的参数 $\mathbf{W}^{(l)}$ 和 $\mathbf{b}^{(l)}$ 计算偏导数, 由于 $\frac{\partial \mathcal{L}(\mathbf{y}, \hat{\mathbf{y}})}{\partial \mathbf{W}^{(l)}}$ 的计算量涉及向量对矩阵的微分, 因此我们先计算 $\mathcal{L}(\mathbf{y}, \hat{\mathbf{y}})$ 关于参数矩阵中每个元素的偏导数, 根据链式法则:

$$\frac{\partial \mathcal{L}(\mathbf{y}, \hat{\mathbf{y}})}{\partial w_{ij}^{(l)}} = \frac{\partial z^{(l)}}{\partial w_{ij}^{(l)}} \frac{\partial \mathcal{L}(\mathbf{y}, \hat{\mathbf{y}})}{\partial z^{(l)}},$$

$$\frac{\partial \mathcal{L}(\mathbf{y}, \hat{\mathbf{y}})}{\partial b^{(l)}} = \frac{\partial z^{(l)}}{\partial b^{(l)}} \frac{\partial \mathcal{L}(\mathbf{y}, \hat{\mathbf{y}})}{\partial z^{(l)}},$$

上述两式中的第二项都是目标函数关于第 l 层的神经元 $z^{(l)}$ 的偏导数, 称为误差项, 可以一次计算得到, 这样我们只需计算三个偏导数, 分别为 $\frac{\partial z^{(l)}}{\partial w_{ij}^{(l)}}$ 、 $\frac{\partial z^{(l)}}{\partial b^{(l)}}$ 和 $\frac{\partial \mathcal{L}(\mathbf{y}, \hat{\mathbf{y}})}{\partial z^{(l)}}$,

计算出上述的三个偏导数后, 可得到:

$$\begin{aligned} \frac{\partial \mathcal{L}(\mathbf{y}, \hat{\mathbf{y}})}{\partial w_{ij}^{(l)}} &= \mathbb{I}_i(a_j^{(l-1)}) \delta_i^{(l)} \\ &= [0, \dots, a_j^{(l-1)}, \dots, 0] [\delta_1^{(l)}, \dots, \delta_i^{(l)}, \dots, \delta_{M_l}^{(l)}]^\top, \\ &= \delta_i^{(l)} a_j^{(l-1)} \end{aligned}$$

其中 $\delta_i^{(l)} a_j^{(l-1)}$ 相当于向量 $\delta^{(l)}$ 和向量 $a^{(l-1)}$ 的外积的第 i, j 个元素。上式可进一步写为：

$$\left[\frac{\partial \mathcal{L}(\mathbf{y}, \hat{\mathbf{y}})}{\partial \mathbf{W}^{(l)}} \right]_{ij} = [\delta^{(l)} (a^{(l-1)})^\top]_{ij}.$$

因此, $\mathcal{L}(\mathbf{y}, \hat{\mathbf{y}})$ 关于第 l 层权重 $\mathbf{W}^{(l)}$ 的梯度为

$$\frac{\partial \mathcal{L}(\mathbf{y}, \hat{\mathbf{y}})}{\partial \mathbf{W}^{(l)}} = \delta^{(l)} (a^{(l-1)})^\top \in \mathbb{R}^{M_l \times M_{l-1}}.$$

同理, $\mathcal{L}(\mathbf{y}, \hat{\mathbf{y}})$ 关于第 l 层偏置 $\mathbf{b}^{(l)}$ 的梯度为

$$\frac{\partial \mathcal{L}(\mathbf{y}, \hat{\mathbf{y}})}{\partial \mathbf{b}^{(l)}} = \delta^{(l)} \in \mathbb{R}^{M_l}.$$

而在本文后续的算法中, 我们主要采用了 *Adam* 以及 *L-BFGS* 优化算法。*Adam* 是一种基于梯度优化的随机优化算法, 它结合了动量优化和 RMSProp 的优点, 在不同的场景下表现出较好的鲁棒性。*Adam* 的核心是通过自适应调整学习率来优化参数, 利用梯度的一阶和二阶矩估计。它的优点主要有自适应调整学习率, 适合稀疏梯度问题以及收敛速度快, 对超参数的敏感性较低。*L-BFGS* 是一种拟牛顿法 (Quasi-Newton Method), 用于无约束连续优化问题, 尤其适合于高维问题中优化光滑函数。它的基本思想为使用目标函数的一阶导数 (梯度) 来更新近似的海森矩阵, 通过存储最近 m 次梯度和参数更新来减少存储开销。它的优点主要有精度高, 适合需要高精度求解的优化问题以及对于中等规模的优化问题, 效率较高。

在计算出每一层的误差项之后, 便可得到每层参数的梯度。因此, 使用误差反向传播算法的前馈神经网络训练过程可分为以下三步:

- (1) 前馈计算每一层的净输入 $z^{(l)}$ 和激活值 $a^{(l)}$, 直至最后一层;
- (2) 反向传播计算每一层的误差项 $\delta^{(l)}$;
- (3) 计算每层参数的偏导数, 并更新参数。

2.2.2 物理信息神经网络 (PINNs)

PINNs (Physics-Informed Neural Networks, 物理信息神经网络) 是一类结合物理信息和深度学习的神经网络模型, 用于解决偏微分方程 (PDEs) 等涉及物理约束的问题, 包括正问题和反问题。正问题指的是根据已知的物理方程、初始条件和边界条件, 求解目标函数 (物理量) 的具体形式。在正问题中, PINNs 可高效地逼近复杂 PDE 的解; 反问题是根据部分观测数据和物理方程, 推断未知的参数、源项或物理规律。反问题相比正问题更为复杂, 因为其通常具有不适定性 (ill-posed), 解可能不唯一或对观测数据的噪声敏感。在反问题中, PINNs 通过观测数据和物理规律相结合, 能够推断未知参数和隐含的物理信息。它们通过引入物理定律 (如守恒方程、边界条件和初始条件) 作为正则化机制, 提高模型的准确性和通用性。

而传统神经网络通常依赖于大规模数据进行训练, 仅使用数据驱动的方法可能会出现以下问题, 第一个问题是数据稀缺性, 在许多实际物理问题中, 实验数据可能难以获得或昂贵。另一个问题则是模型泛化能力不足, 没有物理约束的网络可能在未见过的输入数据上表现不佳。

而 PINNs 的独特之处在于, 它利用已知的物理定律 (通常是以偏微分方程形式存在) 来补充数据的不足。这些物理约束通常包括偏微分方程 (PDEs)、边界条件和初始条件三个方面。通过将这些物理约束引入神经网络的训练过程, PINNs 强制网络的输出满足已知的物理规律即偏微分方程, 而不仅仅是依赖数据拟合。

在这种框架下, 损失函数可以看作是多个误差来源的加权和, 这些误差包括:

- (1) 物理方程残差误差 $\mathcal{L}_{PDE}$, 用于保证神经网络解是满足 PDE 的;
- (2) 初始条件误差 $\mathcal{L}_{IC}$, 确保网络解与已知的初始状态是一致的, 网络在初始时刻的输出与真实值一致;
- (3) 边界条件误差 $\mathcal{L}_{BC}$, 保证解在定义域边界上的行为与物理规律相一致, 如果边界条件未被满足, 即使 PDE 的方程残差很小, 解也可能物理上不成立;

(4) 观测数据误差 $\mathcal{L}_{data}$, 将实验的真实数据融入解的求解过程, 可用于求解反问题;

物理方程残差是 PINNs 的核心部分, 用来强制神经网络解满足 PDE 的约束。假设 PDE 为期权定价模型的一般形式 (2-3)。

PINNs 通过嵌入期权定价方程 (如 Black-Scholes 方程或更复杂的模型) 作为损失函数的一部分, 直接学习期权价格的数值解。在正问题中, 已知模型参数, 如波动率、利率等和边界条件, PINNs 可以有效预测期权价格的空间和时间分布。反问题旨在从期权市场数据中反推出隐含的模型参数, 例如隐含波动率或风险中性参数。在这种情况下, PINNs 将参数的学习与物理约束期权定价方程相结合, 通过优化损失函数包含数据拟合误差和偏微分方程残差实现参数的反演。

PINNs 求解期权定价方程的网络结构图如图 (2-1) 所示:




图 2-1 PINNs 求解期权定价方程网络结构图

2.2.3 期权定价方程正问题求解

在正问题的求解中, 我们已知所有待定参数, 如市场的隐含波动率、无风险利率等, 根据这些已知条件来求解期权价格 $u(S, t)$ 。我们定义了一个神经网络 $u_\theta(S, t)$ 来近似期权的价格, 其中 θ 是神经网络的参数。网络的输入是股票价格 S 和时间 t , 输出是期权的价格 $u(S, t)$ 。神经网络通过拟合期权定价方程 (2-3) 来求解期权价格。为了求解期权价格, PINNs 的优势在于它能够利用自动微分计算神经网络输出相对于输入变量股票价格 S 和时间 t 的导数。

为了训练神经网络并逼近期权定价方程的解, 我们需要定义一个损失函数。

损失函数的构建依赖于 PDE 残差损失、初始条件损失和边界条件损失。PDE 残差损失是指在神经网络中, 我们通过自动微分计算网络输出相对于 S 和 t 的导数, 并将这些值带入期权定价方程中。然后, 我们计算期权定价方程的残差, 并最小化这个残差作为损失函数

$$\mathcal{L}_{\text{PDE}} = \frac{1}{N_{\text{PDE}}} \sum_{i=1}^{N_{\text{PDE}}} \left(\frac{\partial u}{\partial t} - L_S(u_i; \lambda) \right)^2, \quad (2-14)$$

其中, N_{PDE} 是采样的训练点数量, f 是期权定价方程。终止条件对应期权到期时的价格, 在时刻 $t = T$ 期权到期时, 我们希望期权的价格 $u(S, t)$ 与终止条件 $g(S)$ 相符, 例如在欧式看涨期权中, 期权的到期价格 $g(S)$ 是已知的, 为 $\max(S - K, 0)$, 其中 K 为行权价格, 则可以得到终止条件损失为

$$\mathcal{L}_{\text{IC}} = \frac{1}{N_{\text{IC}}} \sum_{i=1}^{N_{\text{IC}}} (u_{\theta}(S_i, T) - g(S_i))^2, \quad (2-15)$$

其中, N_{IC} 是终止条件训练点的数量, $g(S_i)$ 是指到期时期权的价格。期权的边界条件通常包括, 当 $S \rightarrow 0$ 时, 对于看涨期权来说期权价格为零。当 $S \rightarrow \infty$ 时, 期权的价格应该为 $S - K$ 。则边界条件的损失为

$$\mathcal{L}_{\text{BC}} = \frac{1}{N_{\text{BC}}} \sum_{i=1}^{N_{\text{BC}}} (u_{\theta}(S_{\text{BC}}, t_{\text{BC}}) - h(S_{\text{BC}}, t_{\text{BC}}))^2, \quad (2-16)$$

其中, N_{BC} 是边界条件点的数量, $h(S_{\text{BC}}, t_{\text{BC}})$ 是指期权的边界条件。总损失函数是 PDE 残差、终止条件损失和边界条件损失的加权和:

$$\mathcal{L}_{\text{total}} = \lambda_{\text{PDE}} \mathcal{L}_{\text{PDE}} + \lambda_{\text{IC}} \mathcal{L}_{\text{IC}} + \lambda_{\text{BC}} \mathcal{L}_{\text{BC}}, \quad (2-17)$$

其中, $\lambda_{\text{PDE}}, \lambda_{\text{IC}}, \lambda_{\text{BC}}$ 是超参数, 用于调节不同损失项的权重。通过最小化总损失函数 $\mathcal{L}_{\text{total}}$, 我们可以得到期权定价函数 $u_{\theta}(S, t)$ 。优化算法通常使用梯度下降方法, 例如 Adam 优化器, 来更新神经网络的参数 θ 。训练完成后, 使用神经网络 $u_{\theta}(S, t)$ 来预测任意时刻和股票价格下的期权价格。具体算法如算法 (1) 所示。

2.2.4 期权定价方程反问题求解

在反问题中, 目标是通过已知的市场数据, 如市场期权价格来推断期权定价方程中的未知参数 λ , 例如隐含波动率、市场利率等。我们可以定义一个神经网络 $u_{\theta}(S, t, \lambda)$, 该网络不仅输出期权价格 $u(S, t)$, 还通过训练反向推断未知的参

数 λ 。与正问题类似, 反问题的损失函数包含 PDE 残差损失、终止条件损失和边界条件损失, 但损失函数中还需要包括基于市场观测数据的损失项。保持与正问题中相同的, 计算期权定价方程的残差作为 PDE 残差损失:

$$\mathcal{L}_{PDE} = \frac{1}{N_{PDE}} \sum_{i=1}^{N_{PDE}} \left(\frac{\partial u}{\partial t} - L_S(u_i; \lambda) \right)^2. \quad (2-18)$$

假设我们有真实市场的期权价格观测数据 $u_{obs}(S_{data}, t_{data})$ 。我们希望神经网络输出的 $u_{\theta}(S, t, \lambda)$ 与真实市场数据尽量接近, 则数据损失为:

$$\mathcal{L}_{data} = \frac{1}{N_{data}} \sum_{i=1}^{N_{data}} (u_{\theta}(S_{data}, t_{data}, \lambda) - u_{obs})^2. \quad (2-19)$$

与正问题相同, 终止条件和边界条件的损失分别为公式 (2-15) 和公式 (2-16)。

那么总损失函数为在公式 (2-17) 的基础上增加数据损失 $\lambda_{data} \mathcal{L}_{data}$ 。

使用优化器, 如 Adam 来最小化总损失函数, 并通过反向传播优化神经网络的参数 θ 和待定参数 λ 。模型训练后, 神经网络将给出未知参数 λ 的估计值, 例如隐含波动率、市场利率等。具体算法如算法 (2) 所示。

对于期权定价方程的反问题未知参数的反推, 我们常常用于反推隐含波动率、市场利率等。而对于市场利率来说, 我们往往可以用期权期间的平均 1 年期国债收益率为无风险利率来代替。但是对于隐含波动率来说, 我们通常包括指数加权移动平均 (Exponentially Weighted Moving Average, EWMA)、自回归条件异方差 (Auto-Regressive Conditional Heteroscedasticity, ARCH)^[25] 以及广义自回归条件异方差 (Generalized Auto-Regressive Conditional Heteroscedasticity, GARCH)。这些方法的一个显著特点是它们均假设波动率和相关系数不是恒定不变的: 在某些时间段内, 波动率和相关系数可能相对较低, 而在其他时间段则可能显著升高。因此, 这些方法旨在捕捉波动率或相关系数随时间的变化趋势, 从而提供更准确的风险评估和定价依据。

我们考虑使用 GARCH 方法^[26] 求解股票价格的波动率来为后文使用 PINNs 反推期权定价方程中的未知参数波动率 σ 来评估预测效果。

金融时间序列的波动率具有显著的时变特性, 传统假设“条件同方差”(con-

stant conditional variance) 在实证中常被证伪。Engle (1982) 提出的自回归条件异方差模型 (ARCH) 首次系统地捕捉了波动率的自相关性, 但其参数随滞后阶数迅速增加的缺点限制了实用性。为解决这一问题, Bollerslev (1986) 提出了广义自回归条件异方差模型 (GARCH), 通过引入条件方差的自回归项, 显著降低了参数数量, 同时保留了对波动率聚集性 (volatility clustering) 的建模能力。

GARCH 模型的核心假设是: 当前的条件方差 (波动率) 不仅依赖于过去收益率的平方, 还依赖于过去条件方差的估计值。这一假设使得模型能够灵活描述金融资产价格波动的持续性特征。

GARCH 模型的一般形式为:

$$\sigma_t^2 = \omega + \sum_{i=1}^p \alpha_i r_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2, \quad (2-20)$$

其中 σ_t^2 表示第 t 期的条件方差 (波动率平方); r_t 是第 t 期的收益率; $\omega > 0$ 是常数项; $\alpha_i \geq 0$ 和 $\beta_j \geq 0$ 是 ARCH 和 GARCH 项的系数; p 和 q 分别为 ARCH 项和 GARCH 项的滞后阶数。

最常用的 GARCH(1, 1) 模型简化为:

$$\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta \sigma_{t-1}^2, \quad (2-21)$$

该模型仅需估计三个参数 (ω, α, β), 且通过约束条件 $\alpha + \beta < 1$ 确保方差过程的平稳性。而在后续的实例分析中, 我们也会采用 GARCH(1, 1) 模型。

GARCH 模型的优点主要有波动率聚集性、参数精简性以及时间衰减特性三个方面。波动率聚集性是指 GARCH 模型通过滞后项捕捉到“大波动后大波动”的现象, 符合金融市场的实证规律。参数精简性是指相比 ARCH 模型, GARCH 通过引入自回归项显著减少了参数数量, 提高了估计效率。

尽管 GARCH 模型在波动率建模中占据核心地位, 但其仍存在局限性:

(1) 对称性假设: 经典 GARCH 模型假设正负收益率对波动率的影响相同, 而 EGARCH (Nelson, 1991) 和 GJR-GARCH (Glosten et al., 1993) 通过引入不对称项, 捕捉“杠杆效应” (即负收益对波动率的冲击更大)。

(2) 分布假设：条件分布假设（如正态分布）可能低估尾部风险，常用学生 t 分布或广义误差分布（GED）进行修正。

(3) 非线性与多重频率：对于高频数据或极端波动事件，需结合跳跃扩散模型或多频率 GARCH（multifractal models）。

GARCH 模型通过动态捕捉条件方差的时变性，为金融风险度量、衍生品定价和资产配置提供了理论基础。

算法 2-1: 基于物理信息神经网络 (PINNs) 求解期权定价方程正问题**Input:** 终止条件 $u_0(S)$, 边界条件 $u(t)$, 定义域 $\Omega \times [0, T]$, 神经网络参数 θ , 学习率 η , 损失函数 $\mathcal{L}$ **Output:** 训练后的神经网络近似解 $u_\theta(S, t)$ 初始化: 随机初始化神经网络参数 θ 。**while** 未收敛 **do** **步骤 1: 生成训练数据** 在定义域 $\Omega \times [0, T]$ 内采样拉丁超立方点 (S, t) ; 在终止条件 $u(S, 0) = u_0(S)$ 和边界条件 $u(S, t) = u(t)$ 上采样数据点。 **步骤 2: 计算残差**

在拉丁超立方点处计算偏微分方程的残差:

$$\mathcal{R}(S, t; \theta) = \frac{\partial u_\theta}{\partial t} - L_S(u_\theta; \lambda)$$

步骤 3: 定义损失函数

计算总损失函数:

$$\mathcal{L} = \mathcal{L}_{\text{PDE}} + \mathcal{L}_{\text{IC}} + \mathcal{L}_{\text{BC}}$$

其中:

- $\mathcal{L}_{\text{PDE}}$: 偏微分方程残差 $\mathcal{R}(S, t; \theta)$ 的均方误差;
- $\mathcal{L}_{\text{IC}}$: 终止条件的均方误差;
- $\mathcal{L}_{\text{BC}}$: 边界条件的均方误差。

步骤 4: 更新神经网络参数 使用梯度下降更新 θ :

$$\theta \leftarrow \theta - \eta \nabla_\theta \mathcal{L}$$

return $u_\theta(S, t)$

算法 2-2: 利用物理信息神经网络 (PINNs) 求解上述方程的反问题**Input:** 测量数据 $u_{\text{obs}}(S, t)$, 定义域 $\Omega \times [0, T]$, 初始猜测的参数 λ , 神经网络参数 θ , 学习率 η , 损失函数 $\mathcal{L}$ **Output:** 反演得到的参数 λ 和神经网络近似解 $u_{\theta}(S, t)$ **初始化:** 随机初始化神经网络参数 θ 和待求参数 λ 。**while** 未收敛 **do****步骤 1: 生成训练数据**在定义域 $\Omega \times [0, T]$ 内采样拉丁超立方点 (S, t) ;

在终止条件和边界条件处采样数据点;

从观测数据 $u_{\text{obs}}(S, t)$ 中提取数据点。**步骤 2: 计算残差**

在拉丁超立方点处计算偏微分方程的残差:

$$\mathcal{R}(S, t; \theta, \lambda) = \frac{\partial u_{\theta}}{\partial t} - L_S(u_{\theta}; \lambda)$$

步骤 3: 定义损失函数

计算总损失函数:

$$\mathcal{L} = \mathcal{L}_{\text{PDE}} + \mathcal{L}_{\text{IC}} + \mathcal{L}_{\text{BC}} + \mathcal{L}_{\text{Data}}$$

其中:

- $\mathcal{L}_{\text{PDE}}$: 偏微分方程残差 $\mathcal{R}(S, t; \theta, \lambda)$ 的均方误差;
- $\mathcal{L}_{\text{IC}}$: 终止条件的均方误差;
- $\mathcal{L}_{\text{BC}}$: 边界条件的均方误差;
- $\mathcal{L}_{\text{Data}}$: 神经网络解 $u_{\theta}(S, t)$ 与观测数据 $u_{\text{obs}}(S, t)$ 的均方误差。

步骤 4: 更新神经网络参数和待求参数使用梯度下降同时更新 θ 和 λ :

$$\theta \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}, \quad \lambda \leftarrow \lambda - \eta \nabla_{\lambda} \mathcal{L}$$

return 反演得到的参数 λ 和近似解 $u_{\theta}(S, t)$

使用 PINNs (Physics-Informed Neural Networks) 来求解期权定价方程期权价格的定价的优点主要有以下几个方面:

(1) **无网格依赖性:** 与传统的数值方法 (如有限差分法) 不同, PINNs 不需要在空间和时间上定义网格, 这对于高维问题特别有用。

(2) **算法灵活性:** PINNs 可以自然地处理复杂的边界条件、非线性问题以及多种市场模型 (如股息支付、波动率变化等)。

(3) **计算高效:** 在一些复杂的金融衍生品定价问题中, PINNs 能够提供较为高效的解决方案。

同样, 使用 PINNs 求解也可能会存在一下挑战:

(1) **训练的计算复杂性:** 在网络结构较为复杂时, 深度神经网络的训练可能需要大量的计算资源和时间。

(2) **超参数调节:** 如何选择适当的网络架构和超参数 (如层数、神经元数、损失权重等) 对于模型的有效训练至关重要。

(3) **收敛性问题:** 在某些情况下, 训练可能会遇到收敛性问题, 尤其是在模型和数据之间存在较大偏差时。

第三章 数值模拟及实例结果分析

第一节 PINNs 求解期权定价方程正问题

为了验证我们算法的有效性以及普适性,在下文中将分别对 BS 期权定价方程、CEV 定价方程模型以及 Heston 定价方程模型进行数值模拟以及实例的期权价格求解,并于其各自对应的解析解进行效果评估。

3.1.1 BS 期权定价方程的求解

使用 PINNs (Physics-Informed Neural Networks) 来求解欧式看涨期权的 Black-Scholes 期权定价方程 (2-4) 的定价正问题的关键思想是通过神经网络来表示问题的解,也就是期权价格 $u = u(S, t)$,并将该解与相应的物理方程,即 BS 期权定价方程相结合,通过训练神经网络来逼近该解。

具体来说,只需要将算法 (1) 中的期权定价方程 (2-3) 替换为 Black-Scholes 期权定价方程 (2-4),对于欧式看涨期权的 BS 定价方程来说,终止条件为终止条件,即 $u(S, T) = \max(S - K, 0)$,且不存在边界条件。

为了展现我们方法的鲁棒性,接下来会采用两种不同类型的数据来验证模型的有效性。首先,模拟数据在验证 PINN 方法中起着关键作用。通过模拟数据验证算法的优点主要是提供了一个可控、灵活且低成本的环境,可以精确测试算法的性能、鲁棒性和效率。该数据集是通过在价格和时间两个维度上均匀生成的。通过生成模拟数据,我们可以精确控制实验中的所有变量,使我们能够系统地评估模型的性能以及不同训练方案的效果。其次,我们通过 akshare 从 <https://stock.finance.sina.com.cn/>^[27] 获取的真实市场数据来再次验证我们的算法的稳定性和有效性。

3.1.1.1 数值模拟

我们对欧式看涨期权生成模拟数据,具体参数如下表 (3-1) 所示:

下面展示了我们使用 PINNs 求解欧式看涨期权的 BS 方程正问题的结果,

表 3-1 BS 期权定价方程正问题数值模拟参数

Parameter	value
股票价格的波动率 σ	0.2
无风险利率 r	0.05
执行价格 K	50
股票价格范围 $[S_{min}, S_{max}]$	$[0, 100]$
时间范围 $[t_{min}, t_{max}]$	$[0, 1]$
终止条件边界采样数 N_u	1000
PDE 残差采样数 N_f	10000

具体来说, 给定一组 $N_u = 1000$ 在终止条件即 $t = T$ 时刻的数据如下图 (3-1) 所示, 我们通过使用均方误差损失训练一个 8 层的神经网络来学习方程的解, 也就是期权价格 $u(S, t)$ 。每个隐藏层包含 20 个神经元且激活函数为双曲正切函数, 因为 $\tanh(x)$ 是二次可微的, 这与 BS 方程的微分算子是一致的。需要强调的是, 与求解偏微分方程的任何经典数值方法不同, 使用 PINNs 的预测是在不对时空域进行任何离散化的情况下获得的。由前述的 BS 方程的解析解, 我们可以得到在 L_2 范数下测得的预测误差为 $1.63 \cdot 10^{-3}$ 。下图 (3-3)(3-4) 也展示了对于预测解更详细的评估, 图 (3-5) 展示了在不同时刻 $t = 0, 0.25, 0.5, 0.75$ 时刻的解析解与预测解的对比。可以发现, 在使用少量满足终止条件的数据下, PINNs 可以精确地计算出 BS 方程的期权价格。

为了进一步分析我们方法求解正问题的性能, 我们进行了以下的系统性研究, 来量化其针对不同初始点数和训练集大小以及不同神经网络架构的预测精度。在下表 (3-2) 中, 我们实现了在保持 8 层神经网络架构, 每个隐藏层 30 个神经元不变的情况下, 针对不同数量的满足终止条件的训练数据 N_u 以及不同偏微分方程配置数 N_f 所得出的相对 L_2 误差。总体趋势表明, 在偏微分方程配置数 N_f 足够多的情况下, 随着训练数据总数 N_u 的增加, 预测精度会提高。

我们还实现了固定满足终止条件的训练数据 N_u 以及不同偏微分方程配置




图 3-1 终止条件采样点




图 3-2 预测解期权价格三维图




图 3-3 预测解与解析解期权价格




图 3-4 预测解与解析解期权价格误差




图 3-5 不同时刻预测解与解析解期权价格对比

数 N_f 不变的情况下, 通过改变神经网络隐藏层神经元个数的所得出的相对 L_2 误差。具体结果如下表 (3-3) 所示。从图 (3-6) 可以发现, 随着每层隐藏层神经元个数的增加, 误差总体呈减小趋势。

表 3-2 不同初始点数和训练集大小的误差

$N_f \backslash N_u$	1000	5000	10000	15000
250	0.0016	0.0189	0.0251	0.0040
500	0.0044	0.0187	0.0073	0.0255
750	0.0061	0.0319	0.0101	0.0084
1000	0.0046	0.0107	0.0245	0.0050

表 3-3 不同网络结构的误差

Layers $\times$ Neurons	$L2_{error}$
6×5	0.0379
6×10	0.0261
6×20	0.0037
6×30	0.0063
6×40	0.0117
6×50	0.0088
6×60	0.0066




图 3-6 不同网络结构的误差折线图

3.1.1.2 实例分析

相反, 我们可以通过 akshare 从 <https://stock.finance.sina.com.cn/> 获取的真实市场数据来丰富我们对于使用 PINNs 求解 BS 定价方程正问题的效果。在使用真实市场数据的情况下, 增加了模型的实际相关性, 展示了模型在真实金融市场环境中的适用性和表现。我们从新浪财经或者的数据集为我们提供了期权的市场交易数据, 具体来说, 我们选用了以 300ETF 购 6 月 2900 为例的欧式看涨期权, 其中参数包括了根据市场上的期权交易价格反推出的波动率数值 σ (来自 sina), 以期权期间的平均 1 年期国债收益率为无风险利率 r , 期权执行价格 K , 以 300ETF 历史资产价格的最大值和最小值作为股票价格范围, 具体参数取值如下表 (3-4) 所示:

表 3-4 BS 期权定价方程正问题实例分析参数

Parameter	value
股票价格的波动率 σ	0.5131
无风险利率 r	0.0176
执行价格 K	2.9
到期时间 T	1
股票价格范围 $[S_{min}, S_{max}]$	[1.531, 5.631]
时间范围 $[t_{min}, t_{max}]$	[0, T]
终止条件边界采样数 N_u	1000
PDE 残差采样数 N_f	10000

下面展示了我们使用 PINNs 求解 300ETF 购 6 月 2900 的 BS 方程正问题的结果, 与求解正问题模拟数据的过程类似, 给定一组 $N_u = 1000$ 在终止条件即 $t = T$ 时刻的数据如下图所示, 我们通过使用均方误差损失训练一个 8 层的神经网络来学习方程的解, 也就是期权价格 $u(S, t)$ 。每个隐藏层包含 30 个神经元且激活函数为双曲正切函数, 由前述的 BS 方程的解析解, 我们可以得到在 L_2 范

数下测得的预测误差为 $1.38 \cdot 10^{-2}$ 。下图 (3-7)(3-8) 也展示了对于预测解更详细的评估, 图 (3-9) 展示了在不同时刻 $t = 0, 0.25, 0.5, 0.75$ 时刻的解析解与预测解的对比。从结果中, 我们可以发现 PINNs 求解 BS 定价方程对于真实金融市场的期权数据的效果也是满足预期的。




图 3-7 预测解与解析解期权价格




图 3-8 预测解与解析解期权价格误差

3.1.2 CEV 定价模型的求解

3.1.2.1 数值模拟

下面, 我们将使用 PINNs 对欧式看跌期权的 CEV 方程期权价格正问题进行求解, 训练过程与 BS 方程相类似, 区别在于对于 CEV 模型, 损失函数需要包含对非线性项, 即 $S^{2\beta}$ 的计算。因此, 网络在训练时不仅需要拟合线性部分, 还需要适应非线性项带来的影响, 这通常使得训练过程更加复杂, 需要更多的技巧来调整损失函数和优化目标。

与 BS 方程相比, CEV 方程是一个非线性 PDE, 因为扩散项的形式是 $S^{2\beta}$ 而不是常数。这个非线性扩散项使得 CEV 方程更加复杂, 网络在训练时必须处




图 3-9 不同时刻预测解与解析解期权价格对比

理非线性项, 因此网络的损失函数变得更加复杂, 并且训练过程中可能面临梯度消失或梯度爆炸问题, 特别是在 β 非常小或非常大时。具体来说, 训练过程与算法 (1) 相类似, 将 CEV 模型的定价方程 (2-6) 替换期权定价方程 (2-14), 则 CEV 偏微分方程的残差变为 $\mathcal{L}_{\text{PDE}}$ 对于欧式看跌期权来说, 期权价格 $u(S, t)$ 在终止条件上的误差为 $u(T, S_T) = \max(K - S_T, 0)$ 上的误差。

如算法 (1) 训练完成后, 神经网络可以用于预测给定股票价格和时间的期权价格。评估网络的性能通常通过与方程的解析解相比较。

同样的, 我们通过生成模拟数据来验证算法的有效性, 具体参数如下表 (3-5) 所示:

下面展示了我们使用 PINNs 求解欧式看跌期权的 CEV 方程正问题的结果, 具体来说, 给定一组 $N_u = 1000$ 在终止条件即 $t = T$ 时刻的数据, 我们通过使用均方误差损失训练一个 9 层的神经网络来学习方程的解, 也就是期权价

表 3-5 CEV 定价方程正问题数值模拟参数

Parameter	value
股票价格的波动率 σ	0.2
无风险利率 r	0.05
弹性系数 β	0.5
执行价格 K	50
股票价格范围 $[S_{min}, S_{max}]$	$[0, 100]$
时间范围 $[t_{min}, t_{max}]$	$[0, 1]$
终止条件边界采样数 N_u	1000
PDE 残差采样数 N_f	10000

格 $u(S, t)$ 。每个隐藏层包含 20 个神经元且激活函数为双曲正切函数。由前述的 CEV 方程的解析解, 我们可以得到在 L_2 范数下测得的预测误差为 $4.87 \cdot 10^{-2}$ 。下图 (3-10)(3-11) 也展示了对于预测解更详细的评估为了判断预测解的效果, 我们采用已有的欧式看跌期权 CEV 方程期权价格的解析解的结果进行对比, 图 (3-12) 展示了使用 PINNs 的预测解在 $t = 0, 0.25, 0.5, 0.75$ 时刻的结果。




图 3-10 预测解与解析解期权价格

3.1.3 Heston 定价模型的求解

下面我们将对欧式看涨期权的 Heston 模型的期权价格进行求解, Heston 方程与 BS 方程的主要区别在于模型的维度除了股票价格 S 和时间 t , 还有波动率 v , 则 Heston 方程在使用 PINNS 求解时, 神经网络中输入为 (S, v, t) Heston 模型是一个通过两个耦合的随机过程描述股票价格 $S(t)$ 和波动率 $v(t)$ 的动态。而




图 3-11 预测解与解析解期权价格误差




图 3-12 PINNs 求解 CEV 正问题数值模拟的预测结果

三维输入和更多导数计算通常会使得训练过程变得更加复杂。具体来说, 训练过程与算法 (1) 相类似, 用 Heston 模型的期权定价方程 (2-13) 替换期权定价方程 (2-14), 则可以得到残差损失项。对于欧式看涨期权来说, 期权价格 $u(S, t)$ 在终止条件上的误差为 $u(T, S_T) = \max(S_T - K, 0)$ 上的误差。

如算法 (1) 训练完成后, 神经网络可以用于预测给定股票价格和时间以及波动率条件下的期权价格。评估网络的性能通常通过与方程的解析解相比较。而对于 Heston 定价方程 (2-13) 来说, 可以通过傅里叶逆变换来计算数值解。

3.1.3.1 数值模拟

同样的, 我们通过生成模拟数据来验证算法的有效性, 具体参数如下表 (3-6) 所示:

表 3-6 Heston 定价方程正问题数值模拟参数

Parameter	value
无风险利率 r	0.05
波动率均回复速度 κ	2
长期波动率均值 θ	0.04
波动率的波动率 σ	0.3
相关系数 ρ	-0.8
执行价格 K	50
股票价格范围 $[S_{min}, S_{max}]$	$[0, 100]$
时间范围 $[t_{min}, t_{max}]$	$[0, 1]$
波动率范围 $[v_{min}, v_{max}]$	$[0.01, 0.25]$
终止条件边界采样数 N_u	2000
PDE 残差采样数 N_f	10000

下面展示了我们使用 PINNs 求解欧式看涨期权 Heston 方程正问题的结果, 具体来说, 给定一组 $N_u = 2000$ 在终止条件即 $t = T$ 时刻的采样点, 我们通过使用均方误差损失训练一个 7 层的神经网络来学习方程的解, 也就是期权价格 $u(S, v, t)$ 。每个隐藏层包含 40 个神经元且激活函数为双曲正切函数。下图 (3-13) 也展示了对于预测解更详细的评估。为了判断预测解的效果, 我们采用已有的欧式看涨期权 Heston 方程期权价格的解析解的结果进行对比, 图 (3-14) 展示了在固定波动率 $v = 0.4$ 时使用 PINNs 的预测解在 $t = 0, 0.25, 0.5, 0.75$ 时刻的结果。




图 3-13 预测解与解析解期权价格误差




图 3-14 PINNs 求解 Heston 正问题数值模拟的预测结果

3.1.3.2 实例分析

同样，我们可以通过之前提到过的真实市场数据来丰富我们对于使用 PINNs 求解 Heston 定价方程正问题的效果。在使用真实市场数据的情况下，增加了模型的实际相关性，展示了模型在真实金融市场环境中的适用性和表现。具体来说，我们还是选用 300ETF 购 6 月 2900 为例的欧式看涨期权，具体参数取值如下表 (3-7) 所示：

下面展示了我们使用 PINNs 求解 300ETF 购 6 月 2900 的 Heston 方程正问题的结果，与求解正问题模拟数据的过程类似，给定一组 $N_u = 2000$ 在终止条件即 $t = T$ 时刻的数据，我们通过使用均方误差损失训练一个 7 层的神经网络来学习方程的解，也就是期权价格 $u(S, v, t)$ 。每个隐藏层包含 40 个神经元且激活函数为双曲正切函数，由前述的 Heston 方程的解析解，我们可以得到在 L_2 范数下测得的预测误差为 $8.47 \cdot 10^{-2}$ 。下图 (3-16) 也展示了对于预测解更详细的评估，图 (3-15) 展示了在不同时刻 $t = 0, 0.25, 0.5, 0.75$ 时刻的解析解与预测解的对比。从结果中，我们可以发现 PINNs 求解 Heston 定价方程对于真实金融市场的期权数据的效果也是满足预期的。

表 3-7 Heston 期权定价方程正问题实例分析参数

Parameter	value
无风险利率 r	0.0141
波动率均回复速度 κ	2
长期波动率均值 θ	0.05
波动率的波动率 σ	0.3
相关系数 ρ	-0.8
执行价格 K	2.9
股票价格范围 $[S_{min}, S_{max}]$	$[1.531, 5.631]$
时间范围 $[t_{min}, t_{max}]$	$[0, T]$
波动率范围 $[v_{min}, v_{max}]$	$[0.01, 0.3]$
终止条件边界采样数 N_u	2000
PDE 残差采样数 N_f	10000




图 3-15 预测解与解析解期权价格误差

从正问题的求解结果中, 我们可以发现在使用 PINNs 求解期权定价方程时, 不同方程的表现可能会有较大差异。从图 (3-9)、(3-12) 以及 (3-14) 可以得到直观的效果体现, 即相较于 BS 方程以及 CEV 方程模型, Heston 模型使用 PINNs 求解的结果与解析解的结果误差更大。

具体原因可能是因为 BS 方程是一个线性偏微分方程, 结构相对简单, 具有明确的解析解。PINNs 在处理这种简单线性方程时通常表现良好。CEV 方程虽然引入了局部波动率的非线性项, 但本质上仍然是一个一维问题, 求解难度较低。




图 3-16 PINNs 求解 Heston 正问题实例的预测结果

而对于 Heston 方程来说是一个二维非线性偏微分方程, 包含资产价格和波动率两个变量。此外, Heston 模型中存在随机波动率和相关性, 导致方程的复杂性显著增加。PINNs 需要同时逼近两个维度上的解, 这增加了优化的难度。为了改善这一情况, 可以考虑从采样策略 (如自适应采样方法)、调整损失函数权重、网络架构优化等方面入手, 逐步提高求解精度。

第二节 PINNs 反推期权定价方程反问题参数

在实际金融市场中, 通常情况下我们并不知道隐含波动率 σ 或者无风险利率 r , 但我们知道市场上期权的价格。我们的目标是根据期权的市场价格反推这些隐含的参数。PINNs 求解反问题的思想位给定期权的市场价格 $u(S, t)$, 我们希望通过最小化模型预测的期权价格与市场价格之间的差异, 来反推参数隐含波动率 σ 和无风险利率 r 。在使用 PINNs 反推期权定价方程的参数前, 我们可以先对常用的波动率预估模型 GARCH 对模拟数据以及实例数据进行波动率的预估, 作为 PINNs 结果的评估对比。

3.2.1 GARCH 模型波动率预估

我们可以先使用 GARCH(1, 1) 模型对模拟数据的波动率进行估计, 具体参数如下表 (3-8) 所示。图 (3-17) 给出了使用 GARCH(1, 1) 模型对模拟数据波动率的预测结果与真实结果的对比。

表 3-8 GARCH 模型模拟数据参数

Parameter	value
均值 μ	0.001
常数项 ω	0.1
ARCH 系数 α	0.2
GARCH 系数 β	0.7
采样数 N	5000




图 3-17 模拟数据 GARCH 预估波动率与真实波动率对比

同样使用 GARCH 估计 300ETF 的波动率, 图 (3-18) 给出了使用 GARCH(1, 1) 模型对 300ETF 的未来 10 日波动率的预测结果。




图 3-18 ETF300 未来 10 日波动率预测

3.2.2 BS 方程反问题参数反推

与正问题类似, 我们使用神经网络来表示期权价格函数 $u(S, t)$, 但这次的目标还要反推出未知参数隐含波动率 σ 和无风险利率 r , 所以神经网络的输出为 $u(S, t, r, \sigma)$ 。

具体来说, 训练过程与算法 (2) 相同, 只需将期权定价方程 (2-14) 替换为 Black-Scholes 期权定价方程 (2-4) 即可, 而对于数据损失的数据采样点, 只需要根据 BS 方程的解析解 (2-5) 即可获得, 下面给出具体的采样方式。

3.2.2.1 数值模拟

为了展示我们算法的有效性, 下面会给出两种基于模拟数据的结果, 其中一种完全由 BS 期权定价方程解析解生成的数据, 另一种则是在第一种的基础上对数据加上了噪声的干扰。

我们先基于欧式看涨期权的 BS 方程期权价格的解析解生成没有噪声的模拟数据, 具体参数如下表 (3-9) 所示:

下面展示了我们基于无噪声模拟数据使用 PINNs 求解欧式看涨期权的 BS 方程未知参数隐含波动率 σ 和无风险利率 r 反问题的结果, 具体来说, 给定一组 $N_u = 20000$ 的采样数据点如下图 (3-19) 所示, 与求解正问题相似, 我们通过使用均方误差损失训练一个 9 层的神经网络来学习带有未知参数的方程的解,

表 3-9 BS 期权定价方程反问题无噪声模拟数据参数

Parameter	value
股票价格的波动率 σ	0.2
无风险利率 r	0.05
执行价格 K	50
到期时间 T	1
股票价格范围 $[S_{min}, S_{max}]$	$[0, 100]$
时间范围 $[t_{min}, t_{max}]$	$[0, 1]$
采样数 N_u	20000

也就是期权价格 $u(S, t, r, \sigma)$ 。每个隐藏层包含 20 个神经元且激活函数为双曲正切函数, 因为 $\tanh(x)$ 是二次可微的, 这与 BS 方程的微分算子是一致的。下图 (3-20) 也展示了对于包含推导参数的预测解更详细的评估, 展示了在不同时刻 $t = 0.25, 0.5, 0.75$ 时刻的解析解与预测解的对比。




图 3-19 反问题无噪声采样点

如果我们对基于欧式看涨期权的 BS 方程期权价格的解析解生成的模拟数据加入噪声干扰, 服从 $N(0, \sigma_{noise}^2)$ 的正态分布, 同样可以通过使用均方误差损失训练一个 9 层的神经网络来学习方程的解 $u(S, t, r, \sigma)$, 每个隐藏层包含 20 个神




图 3-20 PINNs 求解 BS 方程反问题无噪声的预测结果

经元且激活函数为双曲正切函数。采样点如下图 (3-21) 所示。下图 (3-22) 展示了对于包含推导参数的预测解更详细的评估, 展示了在不同时刻 $t = 0.25, 0.5, 0.75$ 时刻的解析解与预测解的对比。同时, 为了进一步展现使用 PINNs 求解反问题待估参数的有效性和鲁棒性, 我们进行了以下的系统性研究, 通过改变对不同噪声下采样的数据点, 反推未知参数值, 在表 (3-10) 中给出了在无噪声以及不同噪声下采样的数据点的具体反推参数值与正确 PDE 参数值的对比。




图 3-21 反问题有噪声采样点

可以发现, 即使是在增加 10% 噪声采样的数据点的条件下, 所反推出的参数与真实参数无风险利率 r 和隐含波动率 σ 的误差分别仅为 0.06426% 和 6.65571%。




图 3-22 PINNs 求解 BS 方程反问题有噪声的预测结果

表 3-10 不同噪声下 BS 方程反问题求解结果

Correct PDE	$u_t + 0.05Su_S + \frac{1}{2}0.2^2S^2u_{SS} - 0.05u = 0$
Identified PDE (clean data)	$u_t + 0.0500Su_S + \frac{1}{2}0.1963^2S^2u_{SS} - 0.0500u = 0$
Identified PDE (1% noise)	$u_t + 0.0513Su_S + \frac{1}{2}0.1933^2S^2u_{SS} - 0.0513u = 0$
Identified PDE (5% noise)	$u_t + 0.0483Su_S + \frac{1}{2}0.1949^2S^2u_{SS} - 0.0483u = 0$
Identified PDE (10% noise)	$u_t + 0.0506Su_S + \frac{1}{2}0.1867^2S^2u_{SS} - 0.0506u = 0$

3.2.2.2 实例分析

那么同样, 如果我们将求解反问题的思想运用于真实的市场金融数据, 我们可以固定无风险利率 r 为期权期间的平均 1 年期国债收益率, 来反推出股票价格的波动率 σ 。

具体的训练过程与算法 (2) 类似, 将 300ETF 购 6 月 2900 对应的 (u, S, t) 作为数据点进行网络的训练, 我们可以得到波动率 σ 结果为 1.29。我们可以发现这与 sina 给出的隐含波动率有较大的差距, L_2 相对误差为 1.07, 考虑可能是 BS 方程为线性方程结构较为简单, 无法与真实的市场情况相拟合, 我们考虑在更为复杂的 CEV 模型进行反推。

3.2.3 CEV 方程反问题实例参数反推

在上文中, 我们已经实现了对于真实市场金融期权数据 300ETF 购 6 月 2900 的 BS 定价方程反问题隐含波动率 σ 进行反推。同样, 我们可以将这个思想运用在 CEV 定价方程上, 我们可以发现与 BS 方程求解不同的是, 除了隐含

波动率 σ 外, CEV 方程还存在非线性扩散项 $S^{2\beta}$, 所以我们还可以反推出根据市场的实际波动率结构调整模型的未知参数 β 。具体的训练过程与算法 (2) 类似, 将 300ETF 购 6 月 2900 对应的 (u, S, t) 作为数据点进行网络的训练, 我们可以得到波动率 σ 结果为 0.77, β 的结果为 0.53。相较于 BS 方程反推出的隐含波动率 σ_{BS} , σ_{CEV} 的 L_2 相对误差为 0.25。可以发现, 考虑了市场的实际波动率结构调整模型的参数会对股票价格的波动率有更好的反推效果。

通过下表 (3-11) 我们可以直观的对比不同模型对于实例数据波动率预估的结果, 可以发现, 使用 PINNs 对 CEV 方程模型预估的波动率更接近我们的评估标准, 可以认为增加了非线性扩散项的 CEV 模型相较于简单线性的 BS 方程以及常用的 GARCH 模型要更好。

表 3-11 不同模型波动率预估结果对比

Parameter	value
benchmark(from sina)	0.5131
GARCH(1, 1)	0.21
BS 方程	1.29
CEV 方程模型 β	0.77

第四章 结论

本文系统性研究了物理信息神经网络（Physics-Informed Neural Networks, PINNs）在求解金融领域期权定价问题中的应用, 深入分析了其在 Black-Scholes (BS) 方程和 CEV 方程模型的正问题与反问题求解中的表现。

第一节 研究成果

针对 BS 方程的正问题, 本文通过构建结合偏微分方程约束的 PINNs 框架, 将期权价格的求解问题转化为神经网络的优化问题。在训练过程中, 将 BS 方程的控制方程、边界条件及终止条件嵌入 PINNs 的损失函数中, 从而确保神经网络的预测解满足物理规律。实验结果显示, PINNs 方法能够在无网格的条件下, 高效地拟合期权价格的解析解或数值解, 其精度在不同的参数设置下均表现优异。相比于传统的有限差分或有限元方法, PINNs 无需离散网格或计算复杂的数值矩阵, 且更具适应性。

在反问题研究中, 本文利用 PINNs 方法, 从市场提供的期权价格数据中反演模型参数, 如隐含波动率 σ 和无风险利率 r 。通过在损失函数中引入数据误差项以及物理约束项, 神经网络能够实现对隐藏参数的高精度恢复。实验结果表明, 即使在市场数据存在噪声的情况下, PINNs 方法仍具有较强的鲁棒性, 能够稳健地估计出模型参数。此外, 与传统的优化方法相比, PINNs 在处理高维数据和复杂条件下表现出更强的灵活性与收敛性。

为了验证 PINNs 在复杂非线性模型中的适用性, 本文进一步将其用于求解 CEV 方程的正问题。CEV 方程因其引入了非线性波动率函数, 在金融建模中能够更真实地描述资产价格的动态行为。然而, 传统的数值求解方法在处理 CEV 方程时可能面临网格划分、稳定性控制等挑战。本文通过构建针对 CEV 方程的 PINNs 模型, 成功实现了在无网格条件下的高精度解算。实验结果表明, PINNs 不仅能准确捕捉 CEV 模型中的非线性特性, 还展现了极高的收敛速度和对不同边界条件的适应能力。

总体而言, 本文全面研究了物理信息神经网络 (Physics-Informed Neural Networks, PINNs) 在期权定价问题中的应用, 并验证了其在 Black-Scholes (BS) 方程、CEV 方程模型以及 Heston 方程模型求解中的有效性与潜力。从理论研究和实际应用的双重视角, PINNs 展现出显著优势, 但同时也面临一定的挑战。

以下从 PINNs 的优势、局限性、改进方向和未来研究领域四个方面进行详细分析。

第二节 PINNs 算法优势

首先, PINNs 在金融工程中的成功应用得益于其多项独特优势:

- **对偏微分方程的通用性:** PINNs 通过将偏微分方程 (PDE) 的约束直接融入神经网络的损失函数, 不依赖具体的离散化方法, 因此能够适用于广泛的 PDE, 包括线性方程 (如 BS 方程) 和非线性方程 (如 CEV 方程)。其统一框架的特点减少了对不同方程专门设计求解算法的需求。

- **无网格特性:** PINNs 无需像传统数值方法那样构建离散化网格, 避免了因网格分辨率不足导致的数值误差和复杂的网格生成问题。这种特性在高维问题, 如多资产期权定价中尤为重要, 尤其适用于复杂几何边界条件的求解。

- **数据与物理约束的融合能力:** PINNs 将数据驱动与物理模型约束相结合, 在缺乏充分数据的情况下仍能利用 PDE 的内在规律实现高质量求解。同时, 这种融合能够有效对抗噪声数据的干扰, 特别适合金融市场中的不确定性环境。

- **适应复杂金融模型:** PINNs 在 CEV 等非线性模型中的应用表明, 其不仅能够处理复杂的非线性动力学, 还能捕捉传统方法难以模拟的细节行为。此外, 其高度灵活性使其能适配更复杂的金融场景, 如嵌套条件和随机环境下的金融产品建模。

- **参数反演与模型解释:** PINNs 在反问题中的表现证明, 其不仅适合直接求解期权价格, 还能够从市场数据中高效反演关键参数如隐含波动率 σ 和无风险利率 r 。这种能力在实际应用中非常重要, 为金融分析提供了数据驱动与模型解释的有力工具。

第三节 局限性与未来研究方向

尽管 PINNs 表现出以上诸多优势,但其在实际应用中仍面临以下局限性和挑战:

- **训练成本与效率:** PINNs 的训练过程通常依赖梯度下降优化,可能需要大量的迭代才能达到收敛,尤其在处理复杂模型或高维问题时,计算成本较高。且网络的优化效率依赖于神经网络的初始设置和采样策略,在某些情况下可能出现训练收敛慢或卡在局部最优解的问题。
- **高维问题中的性能退化:** PINNs 在理论上可以解决高维问题,但随着维度增加,其损失函数优化变得更加困难,可能面临梯度消失或发散等问题。
- **超参数调节的复杂性:** 神经网络的架构如层数、神经元数量、激活函数的选择以及学习率等超参数对模型性能有重要影响。目前,最佳超参数的选择通常依赖经验或试错法,缺乏系统性的方法论。
- **解释性与可靠性:** PINNs 的预测结果通常是黑箱性质,缺乏对模型行为的直观解释,尤其在金融应用中可能限制用户对其结果的信任度。

针对上述挑战,未来可以考虑通过以下几点来改进 PINNs 的性能:

- **优化算法的改进:** 引入更高效的优化方法^[28],如 Adam 优化器结合二阶方法(如牛顿法)提升收敛速度。或者通过分布式训练和 GPU 加速技术,提升大规模问题的计算效率。
- **高维问题中的适应性增强:** 采用自适应采样策略,如重点采样边界区域或高误差区域,提升高维问题求解的精度。结合降维方法如主成分分析、自动编码器等简化输入维度,降低计算复杂度。
- **自动化超参数调节:** 考虑使用自动机器学习 AutoML 方法,通过网格搜索、随机搜索或贝叶斯优化实现高效的超参数调节。
- **不确定性量化与可信度提升:** 可以考虑融入贝叶斯神经网络方法,提供预测结果的置信区间,增强模型的解释性与可信度。
- **多源数据与多模态学习:** 将市场数据、宏观经济指标和金融模型约束统

一到 PINNs 框架中, 通过多模态学习方法提升模型预测的全面性和精度。

- **网络结构的调整:** 如^[29]所提出的一种具有小泛化误差的新网络——深度算子网络 (DeepONet)。

同样, PINNs 的潜力不仅局限于期权定价问题, 还可以在以下方向开展深入研究:

- **复杂金融产品建模:** PINNs 可用于美式期权、亚式期权、奇异期权等复杂衍生品的定价和风险分析, 特别是在复杂边界条件或非标准约束下表现出独特优势。

- **多因子与随机波动率模型:** PINNs 在处理多因子框架如 Heston 模型或随机波动率假设时具有理论优势。进一步研究其在这些领域的精度和效率将有助于拓展其实际应用范围。

- **实时决策与动态优化:** 将 PINNs 与实时数据处理技术相结合, 构建动态风险管理和实时定价工具, 为高频交易和对冲策略提供支持。

- **理论分析与模型改进:** 从理论层面研究 PINNs 的收敛性和误差界, 为其应用提供更坚实的理论基础。同时, 通过改进神经网络架构, 如图神经网络或变分自编码器, 提升其求解复杂问题的能力。

第四节 研究意义

本文的研究意义在于, 通过引入物理信息神经网络 (PINNs) 来求解 Black-Scholes (BS) 期权定价方程的正问题和反问题, CEV (Constant Elasticity of Variance) 期权定价方程的正问题和反问题, 以及 Heston 期权定价方程的正问题, 突破了传统期权定价方法在复杂市场条件下的局限性。BS 模型作为经典的期权定价工具, 在假设股票价格服从几何布朗运动的前提下, 提供了一个封闭解, 但在现实市场中, 由于波动性变化、跳跃风险等因素, BS 模型往往无法准确反映市场行为。CEV 模型则试图通过引入不同波动性模型来捕捉这些特征, 但同样面临传统数值方法计算效率低、求解困难等挑战。而 Heston 模型通过引入随机波动率 (波动率本身是一个随机过程) 和波动率与资产价格的负相关性, 从而能

够自然解释期权隐含波动率的“微笑”现象。

在本研究中, PINNs 被应用于期权定价的正问题求解, 利用神经网络的强大拟合能力, 通过将物理定律(如 BS 方程、CEV 方程模型以及 Heston 方程模型)作为先验信息进行训练, 能够有效地求解期权价格。相较于传统的有限差分法、蒙特卡罗模拟等数值方法, PINNs 不需要离散化空间和时间变量, 避免了数值误差的积累, 且能够处理高维问题, 使得对复杂金融产品的定价更加高效和精确。此外, PINNs 还具有强大的泛化能力, 能够适应不同类型的期权定价问题, 包括处理不规则的边界条件和不确定性。

另一方面, 本研究还探索了 PINNs 在期权定价反问题中的应用, 即通过观测期权市场价格来反推市场参数(如波动率、利率等), 并与常用的波动率预估模型 GARCH 模型进行效果评估。这一反问题求解在实际金融市场中具有重要意义, 因为在多数情况下, 市场参数并不可直接观测, 而是需要根据期权的市场价格来估计。PINNs 提供了一种无偏且计算效率高的反向求解方法, 能够在不依赖传统的优化算法的前提下, 通过网络的训练直接获得最优参数。

综上所述, 本研究不仅拓展了 PINNs 在金融工程中的应用范围, 也为期权定价问题提供了一种更加精确、高效的解决方案。通过这种新方法, 研究者和从业人员能够在更加复杂和真实的市场环境中进行期权定价与风险管理, 为金融市场的定价模型更新和优化提供理论基础和实践指导。同时, 研究成果也为进一步研究包括波动率微笑、市场不完全性等更复杂期权定价问题提供了新的思路。

参考文献

- [1] TADMOR E. A review of numerical methods for nonlinear partial differential equations[J/OL]. Bulletin of the American Mathematical Society, 2012, 49: 507-554. <https://api.semanticscholar.org/CorpusID:8086254>.
- [2] SMITH C. Option pricing: A review[J/OL]. Journal of Financial Economics, 1976, 3: 3-51. DOI: [10.1016/0304-405X\(76\)90019-2](https://doi.org/10.1016/0304-405X(76)90019-2).
- [3] LATIF N, SHAD S A, USMAN M, et al. Pragmatic comparison analysis of alternative option pricing models[A/OL]. 2023. arXiv: [2309.09890](https://arxiv.org/abs/2309.09890). <https://arxiv.org/abs/2309.09890>.
- [4] HU Y, SHIRVANI A, STOYANOV S, et al. Option pricing in markets with informed traders[J/OL]. International Journal of Theoretical and Applied Finance, 2020, 23(06): 2050037. <http://dx.doi.org/10.1142/S0219024920500375>. DOI: [10.1142/S0219024920500375](https://doi.org/10.1142/S0219024920500375).
- [5] CHIPMAN D M. Overview of solution methods for elliptic partial differential equations on cartesian and hierarchical grids[A/OL]. 2022. arXiv: [2205.03356](https://arxiv.org/abs/2205.03356). <https://arxiv.org/abs/2205.03356>.
- [6] FLOCH F L. Pricing american options with the runge-kutta-legendre finite difference scheme[A/OL]. 2021. arXiv: [2106.12049](https://arxiv.org/abs/2106.12049). <https://arxiv.org/abs/2106.12049>.
- [7] NING A. A mean convection finite difference method for solving black scholes model for option pricing[A/OL]. 2023. arXiv: [2308.06808](https://arxiv.org/abs/2308.06808). <https://arxiv.org/abs/2308.06808>.
- [8] KAZBEK R, ABDUKARIMOVA A. Finite element method for hjb in option pricing with stock borrowing fees[A/OL]. 2025. arXiv: [2501.02327](https://arxiv.org/abs/2501.02327). <https://arxiv.org/abs/2501.02327>.
- [9] DANILUK A, LAKSHTANOV E, MUCHORSKI R. Denoised monte carlo for option pricing and greeks estimation[A/OL]. 2024. arXiv: [2402.12528](https://arxiv.org/abs/2402.12528). <https://arxiv.org/abs/2402.12528>.
- [10] TRINH Y T, HANZON B. Option pricing and cva calculations using the monte carlo-tree (mc-tree) method[A/OL]. 2022. arXiv: [2202.00785](https://arxiv.org/abs/2202.00785). <https://arxiv.org/abs/2202.00785>.

- [11] HUO J. Finite difference solution ansatz approach in least-squares monte carlo[A/OL]. 2024. arXiv: [2305.09166](https://arxiv.org/abs/2305.09166). <https://arxiv.org/abs/2305.09166>.
- [12] HU Y, LINDQUIST W B, RACHEV S T, et al. Option pricing using a skew random walk pricing tree[A/OL]. 2023. arXiv: [2303.17014](https://arxiv.org/abs/2303.17014). <https://arxiv.org/abs/2303.17014>.
- [13] LEBEDEV Y, BANERJEE A. Gaussian recombining split tree[A/OL]. 2024. arXiv: [2405.16333](https://arxiv.org/abs/2405.16333). <https://arxiv.org/abs/2405.16333>.
- [14] BLECHSCHMIDT J, ERNST O G. Three ways to solve partial differential equations with neural networks – a review[A/OL]. 2021. arXiv: [2102.11802](https://arxiv.org/abs/2102.11802). <https://arxiv.org/abs/2102.11802>.
- [15] HUANG S, FENG W, TANG C, et al. Partial differential equations meet deep neural networks: A survey[A/OL]. 2022. arXiv: [2211.05567](https://arxiv.org/abs/2211.05567). <https://arxiv.org/abs/2211.05567>.
- [16] SHI Z, GULGEC N S, BERAHAS A S, et al. Finite difference neural networks: Fast prediction of partial differential equations[A/OL]. 2020. arXiv: [2006.01892](https://arxiv.org/abs/2006.01892). <https://arxiv.org/abs/2006.01892>.
- [17] E W, HAN J, JENTZEN A. Algorithms for solving high dimensional pdes: from nonlinear monte carlo to machine learning[J/OL]. Nonlinearity, 2021, 35(1): 278–310. <http://dx.doi.org/10.1088/1361-6544/ac337f>.
- [18] HABIBA M, PEARLMUTTER B A. Continuous convolutional neural networks: Coupled neural pde and ode[A/OL]. 2021. arXiv: [2111.00343](https://arxiv.org/abs/2111.00343). <https://arxiv.org/abs/2111.00343>.
- [19] RAISSI M, PERDIKARIS P, KARNIADAKIS G. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations[J/OL]. Journal of Computational Physics, 2019, 378: 686–707. <https://www.sciencedirect.com/science/article/pii/S0021999118307125>. DOI: <https://doi.org/10.1016/j.jcp.2018.10.045>.
- [20] BATY H. A hands-on introduction to physics-informed neural networks for solving partial differential equations with benchmark tests taken from astrophysics and plasma physics[A/OL]. 2024. arXiv: [2403.00599](https://arxiv.org/abs/2403.00599). <https://arxiv.org/abs/2403.00599>.

- [21] YAN J, CHEN X, WANG Z, et al. St-pinn: A self-training physics-informed neural network for partial differential equations[A/OL]. 2023. arXiv: [2306.09389](https://arxiv.org/abs/2306.09389). <https://arxiv.org/abs/2306.09389>.
- [22] HUANG X, LIU H, SHI B, et al. A universal pinns method for solving partial differential equations with a point source[C/OL]//RAEDT L D. Proceedings of the Thirty-First International Joint Conference on Artificial Intelligence, IJCAI-22. International Joint Conferences on Artificial Intelligence Organization, 2022: 3839-3846. <https://doi.org/10.24963/ijcai.2022/533>.
- [23] ZHOU W, XU Y F. Data-guided physics-informed neural networks for solving inverse problems in partial differential equations[A/OL]. 2024. arXiv: [2407.10836](https://arxiv.org/abs/2407.10836). <https://arxiv.org/abs/2407.10836>.
- [24] HESTON S. A closed-form solution for options with stochastic volatility with applications to bond and currency options[J/OL]. Review of Financial Studies, 1993, 6: 327-343. <https://api.semanticscholar.org/CorpusID:16091300>.
- [25] ENGLE R F. Autoregressive conditional heteroscedasticity with estimates of the variance of united kingdom inflation[J/OL]. Econometrica, 1982, 50: 987-1007. <https://api.semanticscholar.org/CorpusID:18673159>.
- [26] BOLLERSLEV T. Generalized autoregressive conditional heteroskedasticity[J/OL]. Journal of Econometrics, 1986, 31(3): 307-327. <https://www.sciencedirect.com/science/article/pii/0304407686900631>. DOI: [https://doi.org/10.1016/0304-4076\(86\)90063-1](https://doi.org/10.1016/0304-4076(86)90063-1).
- [27] KING A. Akshare[J/OL]. GitHub repository, 2019. <https://github.com/akfamily/akshare>.
- [28] JAGTAP A D, KAWAGUCHI K, KARNIADAKIS G E. Adaptive activation functions accelerate convergence in deep and physics-informed neural networks[J/OL]. Journal of Computational Physics, 2020, 404: 109136. <https://www.sciencedirect.com/science/article/pii/S0021999119308411>. DOI: <https://doi.org/10.1016/j.jcp.2019.109136>.
- [29] LU L, JIN P, PANG G, et al. Learning nonlinear operators via deeponet based on the universal approximation theorem of operators[J/OL]. Nature Machine Intelligence, 2019, 3: 218 - 229. <https://api.semanticscholar.org/CorpusID:233822586>.

第五章 致谢

首先,我要感谢我的导师张冉副教授,她不仅在学术上提供了宝贵的指导,而且在研究过程中给予了我极大的支持和鼓励。她严谨的学术态度和深厚的专业知识是我学术旅程中的重要灯塔。

我特别感谢我的女朋友 CQQ 以及最可爱的小狗 Hachi,她们在我撰写论文期间提供了无私的支持和帮助。在我面对研究中的挑战和困难时,她们始终在旁边鼓励我,给我精神上的支持。她们的理解和爱是我完成这项研究的重要动力。

最后,我要感谢我的家人对我的学术追求和个人成长的无条件支持和鼓励。在遇到困难和挑战时,是他们给予了我前进的动力和支持。

通过这份致谢,我希望表达我对所有支持者的深深的感激之情。我们的共同努力和协作,使得本文能够顺利完成,并希望能对相关领域做出一些贡献。